



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO CEARÁ
IFCE CAMPUS CEDRO
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

DANIEL SANTOS DA SILVA

UM MÉTODO DE VISÃO COMPUTACIONAL PARA IDENTIFICAÇÃO DE
NÓDULOS EM IMAGENS DE MAMOGRAFIA DIGITAL POR MEIO DE ANÁLISE
DE TEXTURA

CEDRO – CE

2019

DANIEL SANTOS DA SILVA

UM MÉTODO DE VISÃO COMPUTACIONAL PARA IDENTIFICAÇÃO DE NÓDULOS
EM IMAGENS DE MAMOGRAFIA DIGITAL POR MEIO DE ANÁLISE DE TEXTURA

Trabalho de Conclusão de Curso apresentado ao Curso de bacharelado em Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Ceará – IFCE – Campus Cedro, como requisito parcial para obtenção do Título de Bacharel em Sistemas de Informação.

Orientador: Prof. Me. Emmanuel Diego Gonçalves de Freitas

CEDRO – CE

2019

Dados Internacionais de Catalogação na Publicação
Instituto Federal do Ceará - IFCE
Sistema de Bibliotecas - SIBI
Ficha catalográfica elaborada pelo bibliotecário Robson Souza (CRB3/1438)

S586m Silva, Daniel Santos da.

Um método de visão computacional para identificação de nódulos em imagens de mamografia digital por meio de análise de textura / Daniel Santos da Silva. - 2019.
78 f. : il. color.

Trabalho de Conclusão de Curso (graduação) - Instituto Federal do Ceará, Bacharelado em Sistemas de Informação, Campus Cedro, 2019.

Orientação: Prof. Me. Emmanuel Diego Gonçalves de Freitas.

1. Processamento Digital de Imagens. 2. Visão Computacional. 3. Análise de Textura. 4. Mamografia Digital. I. Título.

CDD 005.74

DANIEL SANTOS DA SILVA

UM MÉTODO DE VISÃO COMPUTACIONAL PARA IDENTIFICAÇÃO DE NÓDULOS
EM IMAGENS DE MAMOGRAFIA DIGITAL POR MEIO DE ANÁLISE DE TEXTURA

Trabalho de Conclusão de Curso apresentado
ao Curso de bacharelado em Sistemas de
Informação do Instituto Federal de Educação,
Ciência e Tecnologia do Ceará – IFCE –
Campus Cedro, como requisito parcial para
obtenção do Título de Bacharel em Sistemas de
Informação.

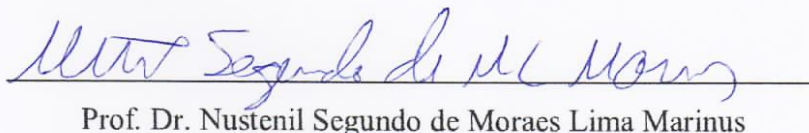
Aprovada em: 31/05/2019

BANCA EXAMINADORA



Prof. Me. Emmanuel Diego Gonçalves de Freitas (Orientador)

Instituto Federal de Educação, Ciência e Tecnologia do Ceará (IFCE – *Campus Cedro*)



Prof. Dr. Nustênil Segundo de Moraes Lima Marinus

Instituto Federal de Educação, Ciência e Tecnologia do Ceará (IFCE – *Campus Crato*)



Prof. Esp. Romulo Cesar Cunha Lima

Instituto Federal de Educação, Ciência e Tecnologia do Ceará (IFCE – *Campus Cedro*)

Dedico este trabalho ao meus pais, Adenir Santos e Francisco Soares, ao meu irmão, Junior Soares, a minha namorada, Joyce Oliveira, por se fazerem essenciais nessa jornada, e a todos meus familiares e amigos por terem me apoiado e incentivado não medindo esforços para que eu pudesse obter êxito.

AGRADECIMENTOS

Agradeço primeiramente a Deus, por ter me permitido chegar até onde cheguei, por toda a força e saúde para enfrentar os desafios, sempre com fé, esforço e a certeza que tudo daria certo, não me deixando desistir.

Meu muito obrigado, aos meus pais, Adenir Santos e Francisco Soares, por sempre estarem presentes, ao meu irmão, Junior Soares, por toda a ajuda durante este percurso, a minha namorada, Joyce Oliveira, por me incentivar e me apoiar em todos os momentos, e a todos os meus familiares.

Agradeço ao meus amigos e colegas, por tornarem o caminho mais leve, pelas brincadeiras e alegrias, em especial aos amigos que trago desde o ensino médio, Felipe Almeida e Wellington Costa, e aos amigos que conheci nesta longa jornada, em especial a minha dupla de três, Gabriela Nayara e Expedito Alves, sou grato pelo companheirismo e todas as alegrias proporcionadas.

Agradeço a todos que compõem o IFCE - Campus Cedro, do pessoal da portaria até a alta gestão por toda a contribuição e receptividade a qual me recebem diariamente.

Agradeço, a todos os professores que não mediram esforços para nos repassar todo o conhecimento e valores empenhando-se para nos tornar uma pessoa mais preparada para os desafios da vida, em especial aos professores Ednael Macedo, Anderson Aragão, Elias Paulino e Renato William, por toda a amizade.

Agradeço ao amigo Patrício Corsino, pela contribuição e esforço para que pudesse executar meu sistema.

Agradeço ao meu amigo Luciano Marinho, pela amizade, ajuda e por todos os ensinamentos proporcionado neste período.

Agradeço fortemente ao meu amigo e orientador Emannuel Diego pela pessoa que é, que além de ensinar importantes conteúdos didáticos e a ser um bom profissional, me ensinou valores morais. Agradeço também pelos momentos de descontração para aliviar o estresse e manter a calma nos momentos difíceis. Agradeço principalmente, por ter acreditado no meu potencial, não medindo esforços para que pudesse chegar até aqui.

E meu muito obrigado a todos, que torceram e acreditaram que eu poderia chegar até aqui.

"Você pode até ter medo. Mas ande, caminhe, e só não pare, não pare".

(Guilherme de Sá)

RESUMO

Os altos índices de câncer de mama têm tornado essa patologia a segunda maior em ocorrência, ocupando também a quinta colocação como causa de morte por câncer mundialmente, ao ponto que é responsável pela morte de 198.000 mulheres por ano, o que o torna ainda a segunda causa de mortes entre as mulheres por câncer no mundo. A mamografia é um dos principais e mais confiáveis exames para rastreio do câncer de mama, entretanto, os exames de imagens, especificamente a mamografia, por vezes são concebidos com a presença de ruídos e baixo contraste, além de diversos outros fatores que influenciam na qualidade, que podem dificultar a interpretação e, ocasionalmente, o diagnóstico médico. Em função disso, novas tecnologias para o processamento de imagens médicas surgem com o propósito de melhorar a precisão e o tempo dos exames, variáveis importantes para a tomada de decisão por parte do especialista. Desse modo, esta pesquisa tem o objetivo de desenvolver um método computacional para detecção dos nódulos mamários de forma a classificar as imagens em normais (sem tumor) e anormais (com tumor), através do processamento de imagens de mamografia por meio da análise de textura e clusterização com *k-means*. Com isso, pretende-se contribuir com a proposta de um método para auxiliar no diagnóstico médico de forma precisa, por meio da identificação dos nódulos em imagens de mamografias, tendo em vista que, o diagnóstico precoce, aumenta a chance de resultados positivos no tratamento. Nessa perspectiva, são utilizados diversos métodos, baseados no uso de descritores de textura de Haralick, com a finalidade de segmentar, reconhecer e identificar características da região de interesse na imagem de mamografia analisada. Para tanto, analisou-se quais os descritores com maior potencial discriminatório, e realizou-se a classificação de informações de textura extraídas da imagem de mamografia por meio do algoritmo de clusterização *k-means*. Ao final do processo de segmentação, um contorno é delineado automaticamente em volta da região segmentada sem a necessidade de uma intervenção humana. Os resultados obtidos pelo método proposto foram comparados com o padrão ouro, dado pela segmentação manual das regiões de nódulos. Nos testes realizados, o sistema obteve bons resultados para as medidas de sensibilidade (84,19%), especificidade (99,82%) e acurácia (99,75%), bem como para área sob a curva ROC, que obteve um valor de 0,925, mostrando que o método proposto possui um bom desempenho e uma excelente qualidade de classificação, sendo capaz de promover a classificação necessária para identificação de nódulos mamários com precisão.

Palavras-chave: Identificação de nódulos mamários. Análise de Textura. Visão Computacional.

ABSTRACT

The high rates of breast cancer have made this condition the second highest in occurrence, occupying also the fifth place as cause of death from cancer worldwide, to the point that is responsible for the death of 198.000 women per year, making it still the second leading cause of deaths among women from cancer in the world. Mammography is one of the leading and most reliable tests for screening of breast cancer, however, the examination of images, specifically mammography, are sometimes designed with the presence of noise and low contrast, in addition to several other factors that influence the quality, which can make it difficult to interpretation and, occasionally, the medical diagnosis. In addition, new technologies for processing of medical images arise with the purpose of improving the accuracy and the time of the examinations, the important variables for the decision-making on the part of the expert. Thus, this research has the objective of developing a computational method for the detection of breast lumps, in order to classify the images into normal (non-tumor) and abnormal (with tumor), through the image processing of mammograms by means of the analysis of the texture and clustering with k-means. With this, it is intended to contribute with the proposal of a method to assist in the medical diagnosis of the precise form, by means of the identification of the nodules in the images of mammograms, in view of that, early diagnosis, increases the chance of positive results in the treatment. In this perspective, are used various methods, based on using descriptors of the texture of Haralick, with the purpose to segment, recognize and identify characteristics of the region of interest in an image of the mammogram analyzed. For both, we assessed which of the descriptors with the highest discriminatory potential, and held the classification of texture information extracted from the image of the mammogram by means of the algorithm of clustering k-means. At the end of the process of segmentation, a contour is delineated automatically in the back of the targeted region without the need of a human intervention. The results obtained by the proposed method were compared with the gold standard, given by the segmentation manually from the regions of the nodules. In tests, the system obtained good results for the measures of sensitivity (84,19%), specificity (99,82%) and accuracy (99,75%), as well as to the area under the ROC curve, we obtained a value of 0,925, showing that the proposed method has a good performance and an excellent ranking quality, being able to promote the classification necessary for identification of breast lumps with precision.

Keywords: Identification of breast lumps. Texture analysis. Computer vision.

LISTA DE FIGURAS

Figura 1 — Esquema simplificado de um aparelho de mamografia digital.....	23
Figura 2 — Imagem referente a mama esquerda e direita com incidência CC (a). Imagem referente a mama esquerda e direita com incidência MLO (b).....	24
Figura 3 — Anatomia da mama.....	26
Figura 4 — Quadrantes da mama.....	28
Figura 5 — Imagens de mamografia com três tipos de diagnósticos (a) mamografia saudável. (b) mamografia com nódulo benigno. (c) mamografia com nódulo maligno.	29
Figura 6 — Os quadros brancos sobreposto nas imagens mostram as propriedades de regiões suaves (a), regulares (b) e rugosas (c).....	30
Figura 7 — Exemplo de uma co-ocorrência dos níveis de cinza, em relação à distância.....	32
Figura 8 — Ângulos para cálculo da GLCM alinhados na direção $\theta = 0^\circ$, $\theta = 45^\circ$, $\theta = 90^\circ$ e $\theta = 135^\circ$	32
Figura 9 — (a) Imagem $N_x \times N_y$. (b) Matriz de co-ocorrência da imagem ($d = 1$, $\theta = 0$).....	32
Figura 10 — Composição de uma GLCM (b) a partir de uma imagem hipotética (a).....	33
Figura 11 — Exemplo de uma imagem hipotética (a) e o processo de cálculo (b) e normalização (c) de matriz de co-ocorrência.....	34
Figura 12 — Padrões de imagens aleatórios (a), periódicos (b) e mistos (c).....	34
Figura 13 — Matrizes de co-ocorrência 256×256 , G1, G2 e G3.....	35
Figura 14 — Fluxograma da fase de análise estatística dos melhores descritores de Haralick.....	50
Figura 15 — Fluxograma da classificação e segmentação (Etapa 2, Etapa 3, Etapa 4 e Etapa 5).....	51
Figura 16 — Etapas do processo de segmentação dos nódulos. (a) Imagem de mamografia utilizada. (b) Imagem pré processada. (c) Saída do <i>k-means</i> . (d) Imagem dos 3 descritores somados. (e) Imagem binarizada. (f) pós	

processamento sobre a imagem binarizada. (g) imagem final.....	52
Figura 17 — Exemplo de Gráfico ROC básico com 5 classificadores discretos.....	54
Figura 18 — Curva ROC e a qualidade no diagnóstico.....	55
Figura 19 — Padrão ouro das imagens com nódulos.....	61
Figura 20 — Padrão ouro das imagens saudáveis.....	61
Figura 21 — Resultados obtidos com as imagens diagnosticadas com nódulos.....	64
Figura 22 — Resultados obtidos com as imagens diagnosticadas sem nódulo.....	64

LISTA DE TABELAS

Tabela 1 — Valor da média, desvio padrão e significância de cada descritor.....	56
Tabela 2 — Resultados obtidos para cada imagem a partir do método utilizado.....	62

LISTA DE QUADROS

Quadro 1 — Matriz de confusão em um teste de detecção de presença/ausência de doença.....	53
Quadro 2 — Qualidade do diagnóstico em relação a área da curva ROC.....	55

LISTA DE GRÁFICOS

Gráfico 1	— Segundo Momento Angular.....	58
Gráfico 2	— Contraste.....	58
Gráfico 3	— Correlação.....	58
Gráfico 4	— Variância.....	58
Gráfico 5	— Homogeneidade.....	58
Gráfico 6	— Soma das Médias.....	58
Gráfico 7	— Soma da Variância.....	59
Gráfico 8	— Entropia da Soma.....	59
Gráfico 9	— Entropia.....	59
Gráfico 10	— Variância da Diferença.....	59
Gráfico 11	— Entropia da Diferença.....	59
Gráfico 12	— Informações de Med. de Corr. 1.....	59
Gráfico 13	— Informações de Med. de Corr. 2.....	60
Gráfico 14	— Curva ROC para o classificador utilizado.....	65

LISTA DE ABREVIATURAS E SIGLAS

Ac	Acurácia
AG	Algoritmo Genético
AS	<i>Average Sum</i>
ASM	<i>Angular Second Moment</i>
AUC	<i>Area Under Curve</i>
CAD	<i>Computer Aided Diagnosis</i>
CADDx	<i>Computer-Aided Detection and Diagnosis</i>
CC	Crânio Caudal
CLAHE	<i>Contrast Limited Adaptive Histogram Equalization</i>
DDSM	<i>Digital Database for Screening Mammography</i>
DV	<i>Difference Variance</i>
Esp	Especificidade
FCBF	<i>Fast Correlation based feature Selection</i>
FN	Falso Negativo
FP	Falso Positivo
GLCM	<i>Gray Level Co-Occurrence Matrix</i>
GLFOS	<i>Gray Level First Order Statistics</i>
IDM	<i>Inverse Difference Moment</i>
INCA	Instituto Nacional de Câncer
KNN	<i>K-Nearest Neighbors</i>
KPCA	<i>Kernel Principal Component Analysis</i>
LBP	<i>Local Binary Pattern</i>
LDA	<i>Linear Discriminant Analysis</i>
LSDA	<i>Locality Sensitive Discriminant Analysis</i>
MIAS	<i>Mammographic Image Analysis Society</i>
MLO	<i>Médio-Lateral Oblíqua</i>
MLP	<i>Multilayer Perceptron</i>
MRMR	<i>Minimum Redundancy Maximum Relevance</i>
NPE	<i>Neighborhood Preserving Embedding</i>
PCA	<i>Principal Component Analysis</i>

QIE	Quadrante Inferior Externo
QII	Quadrante Inferior Interno
QSE	Quadrante Superior Externo
QSI	Quadrante Superior Interno
RF	<i>Random Forest</i>
ROC	<i>Receiver Operating Characteristic</i>
SE	<i>Sum Entropy</i>
Sen	Sensibilidade
SPSS	<i>Statistical Package to Social Sciences</i>
SUM	<i>Sum Variance</i>
VN	Verdadeiro Negativo
VP	Verdadeiro Positivo
VPP	Valor Preditivo Positivo

LISTA DE SÍMBOLOS

μ	Coeficiente de Atenuação Linear
δ	Desvio Padrão
θ	Posição angular do nível de cinza j de um <i>pixel</i> dentro de sua vizinhança
d	Distância entre dois níveis de cinza de uma GLCM
i	Referência horizontal dos <i>pixels</i> de uma imagem
j	Referência vertical dos <i>pixels</i> de uma imagem
N_g	Quantidade de níveis de cinza de uma imagem
N_x	Número de <i>pixels</i> na direção horizontal de uma GLCM
N_y	Número de <i>pixels</i> na direção vertical de uma GLCM
$P(i,j)$	Valor do elemento na posição (i,j) em uma GLCM
f_1	Segundo Momento Angular
f_2	Contraste
f_3	Correlação
f_4	Variância
f_5	Homogeneidade
f_6	Soma das Médias
f_7	Soma da Variância
f_8	Entropia da Soma
f_9	Entropia
f_{10}	Variância da Diferença
f_{11}	Entropia da Diferença
f_{12}	Informações de Medidas de Correlação 1
f_{13}	Informações de Medidas de Correlação 2
f_{14}	Coeficiente de Correlação Máximo

SUMÁRIO

1 INTRODUÇÃO	18
2 FUNDAMENTAÇÃO TEÓRICA	21
2.1 Mamografia	21
2.1.1 Contextualização	21
2.1.2 Formação e apresentação da imagem	23
2.1.4 Anatomia e Fisiologia da Mama	25
2.1.5 Fisiopatologia do câncer de mama	27
2.2 Análise de Textura	29
2.2.1 Contextualização	29
2.2.2 Matriz de Co-ocorrência de Tons de Cinza	31
2.2.3 Descritores de Haralick	35
2.2.3.1 Segundo Momento Angular	36
2.2.3.2 Contraste	37
2.2.3.3 Correlação	37
2.2.3.4 Variância (soma dos quadrados) e desvio padrão	37
2.2.3.5 Homogeneidade ou momento da diferença inversa	38
2.2.3.6 Soma das Médias	38
2.2.3.7 Soma da Variância	38
2.2.3.8 Entropia da Soma	39
2.2.3.9 Entropia	39
2.2.3.10 Variância da Diferença	39
2.2.3.11 Entropia da Diferença	40
2.2.3.12 Informações de Medidas de Correlação 1	40
2.2.3.13 Informações de Medidas de Correlação 2	41
2.2.3.14 Coeficiente de Correlação Máximo	41
2.4 Trabalhos relacionados	41
2.4.1 Trabalho de Radovic et al.	42
2.4.2 Trabalho de Gaike et al.	42
2.4.3 Trabalho de Raghavendra et al.	43
2.4.4 Trabalhos Perez et al.	44
2.4.5 Trabalho de Ghongade e Wakde	44

3 MATERIAIS E MÉTODOS	46
3.1 Classificação da pesquisa	46
3.2 Materiais.....	47
3.2.1 Opencv.....	47
3.2.2 Linguagem C++.....	47
3.2.3 IDE Qt Creator	47
3.2.4 Base de imagens	48
3.2.5 SPSS Statistics	48
3.2.6 O classificador	48
3.3 Métodos	49
3.3.1 Metodologia para avaliação do potencial discriminatório dos descritores de Haralick	50
3.3.2 Metodologia para classificação e segmentação	51
3.3.3 Metodologia para avaliação e interpretação	52
4 RESULTADO E DISCUSSÕES	56
4.1 Análise estatística dos descritores de Haralick como medidas para classificação de textura da mamografia	56
4.2 Análise da classificação e identificação.....	60
5 CONCLUSÃO	66
5.1 Considerações Finais.....	66
5.2 Trabalhos Futuros.....	67
REFERÊNCIAS.....	68

1 INTRODUÇÃO

O câncer de mama tem se tornado o segundo maior em ocorrência no mundo, com 1,7 milhões de casos, ficando atrás somente do câncer de pulmão, com 1,8 milhões de casos (FERLAY *et al.*, 2014). No Brasil, estima-se que para o biênio de 2018-2019, o câncer de mama será o mais frequente (29,5%) entre as mulheres, com exceção do câncer de pele não melanoma (INCA, 2017).

Além do câncer de mama ser um dos cânceres de maior ocorrência, Ferlay *et al.* (2014) afirmam ainda que este [o câncer de mama] ocupa a quinta colocação como causa de morte por câncer no mundo. Nesse cenário percebe-se que a ocorrência é mais comum em mulheres - apesar de também ser registrada em homens - sendo a segunda causa de mortes por câncer com 198.000 vítimas por ano no mundo conforme aponta Ferlay *et al.* (2014).

O diagnóstico de câncer de mama é realizado primeiramente por meio do autoexame, muitas vezes ineficiente quanto ao diagnóstico da patologia quando esta se encontra em estado inicial (MARQUES, 2001), é perante essa dificuldade que o mais recomendável é a mamografia. Pereira *et al.* (2014) cita que diversas pesquisas científicas e organizações internacionais comprovam que a mamografia, para rastreio do câncer de mama, é um dos principais e mais confiáveis exames, mostrando onde encontra-se a anomalia, sendo ela benigna ou maligna. Assim, segundo Diniz (2017) o médico especialista, a partir da análise da simetria, utiliza-se da comparação das mamografias para examinar as anomalias presentes, sendo conhecida como análise bilateral.

Entretanto, os exames de imagens, especificamente a mamografia, por vezes são concebidos com a presença de ruídos e baixo contraste, além de diversos outros fatores que influenciam na qualidade, como: condições de revelação, fatores de digitação e manipulação do filme, que podem dificultar a interpretação e, ocasionalmente, o diagnóstico médico (RIBEIRO, 2006). Com vista nessa problemática, novas tecnologias para o processamento de imagens médicas surgem como resultados de diversos estudos e pesquisas desenvolvidas com o propósito de melhorar a precisão e o tempo dos exames, variáveis importantes para a tomada de decisão por parte do especialista.

Logo, a introdução dessas tecnologias, permite uma maior agilidade e facilidade no diagnóstico, provendo assim, melhores tratamentos. Barra *et al.* (2006) colaboram nessa perspectiva, afirmando que a utilização dessas tecnologias, trouxeram diversos benefícios para a luta contra várias doenças, e que vem contribuindo em larga escala para a solução de problemas, proporcionando melhores condições de vida e saúde.

Dentro do cenário das tecnologias desenvolvidas para auxiliar o diagnóstico médico são desenvolvidos diversos métodos computacionais para interpretação e análise de imagens, comumente conhecido como sistemas CADDx (*Computer-Aided Detection and Diagnosis*) que, por meio da análise computadorizada das imagens, identificam precocemente patologias para as quais foram especializadas e, com isso, contribuem no tratamento ainda no período inicial da doença.

No desenvolvimento dessas importantes ferramentas, a Visão Computacional e técnicas de Aprendizado de Máquina são cada vez mais utilizados aliados à literatura médica, seja para se conseguir melhorias das imagens, o realce ou a diminuição de ruídos, seja para a segmentação de partes de interesse ou até analisar, automaticamente, variáveis ou características que permitam a interpretação da imagem por parte do computador.

O uso dessas técnicas vem sendo empregadas em diversas pesquisas, mostrando-se eficientes em diferenciar, segmentar, extrair e reconhecer regiões de interesse automaticamente ou semi-automaticamente, em imagens para os mais variados fins. Os sistemas de Visão Computacional são basicamente divididos em cinco etapas: aquisição de imagens, pré-processamento, segmentação, extração de atributos e reconhecimento e interpretação (GONZALEZ; WOODS, 2010).

Na fase de aquisição de imagens, é realizada a obtenção da imagem por meio de sensores, câmeras digitais, Raios-X, dentre outros. Dentre os aspectos envolvidos nesta etapa, pode-se mencionar a escolha do sensor, as condições de iluminação e a resolução (MARQUES FILHO; VIEIRA NETO, 1999). Para a fase seguinte (pré-processamento), fica a incumbência de realizar operações para a melhoria das condições da imagem, tais como a redução de ruídos, suavização, equalizações de brilho e contraste.

Após as correções realizadas, a fase de segmentação é utilizada para a identificação das partes de interesse, de modo a dividir em áreas similares a partir de propriedades pré-estabelecidas. Na etapa de extração de atributos, conhecida também como etapa de representação e descrição, busca escolher uma forma de descrever os objetos segmentados. Nesta fase, as características das áreas segmentadas são obtidas e, por diversas das vezes, são representadas por dados métricos chamados de descritores (FREITAS, 2016).

Na última fase, a de reconhecimento e interpretação, são atribuídos aos objetos rótulos baseados em suas características, traduzidas por seus descritores que foram obtidos na etapa de extração de atributos (MARQUES FILHO, VIEIRA NETO, 1999).

Desse modo, para a identificação dos nódulos em mamografias, esta pesquisa tem o objetivo de desenvolver um método computacional para detecção dos nódulos mamários de

forma a classificar as imagens em normais (sem tumor) e anormais (com tumor), através do processamento de imagens de mamografia por meio da análise de textura e clusterização com *k-means*.

Para conseguir atingir este objetivo, busca-se analisar as formas dos nódulos presentes na mama; analisar estatisticamente os melhores descritores de Haralick para a mamografia; segmentar as partes de interesse por meio dos descritores de Haralick e o algoritmo *k-means*; e agrupar em classes normais e anormais.

Com isso, a presente pesquisa, face aos crescentes índices de câncer de mama, pretende contribuir com a proposta de um método para auxiliar no diagnóstico médico de forma precisa, por meio da identificação dos nódulos em imagens de mamografias, tendo em vista que, o diagnóstico precoce, aumenta a chance de resultados positivos no tratamento. Com um impacto sócio-científico direto, o presente trabalho possui relevante importância para a pesquisa em computação aplicada, em especial na área de Visão Computacional aplicada a imagens médicas, onde um processo colaborativo entre tecnologia de informação e medicina existe com o propósito de diminuir a subjetividade no diagnóstico, bem como os índices de mortes por doenças diagnosticadas por meio de imagens digitais.

Para registrar o exposto, este trabalho está organizado em 5 seções: a presente introdução, o referencial teórico, materiais e métodos, resultados e discussões e as considerações finais, respectivamente. Na seção 1, a introdução, é tratada a problemática, os objetivos da pesquisa, a relevância da pesquisa proposta e sua justificativa. Na seção 2, é feita uma fundamentação teórica, onde são apresentadas informações importantes para o exame de mamografia, abordando assuntos como o histórico do diagnóstico por imagem até a fisiopatologia do câncer de mama. Ainda nessa seção, é teorizado o conceito de análise de textura, quando se apresenta os descritores de Haralick, peça fundamental para os objetivos propostos. Nos procedimentos metodológicos, descritos na seção 3, são abordados os procedimentos adotados para a implementação da metodologia computacional, bem como, as ferramentas utilizadas. Na seção 4, são abordados os resultados e as discussões sobre os testes realizados, avaliados por um viés estatístico por meio das medidas de sensibilidade, especificidade e da acurácia, bem como por uma curva ROC, como forma de avaliar o desempenho da classificação. Por fim, na seção 5, são feitas as considerações finais com a apresentação de uma reflexão acerca do tema em estudo e do que se conseguiu ao final do desenvolvimento proposto, bem como as sugestões para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Nesta seção, serão abordados os termos e conceitos fundamentais da pesquisa, terão enfoque assuntos como mamografia, análise de textura, e por fim serão apresentados os trabalhos relacionados com a pesquisa aqui desenvolvida.

2.1 Mamografia

Nos tópicos seguintes, busca-se apresentar conceitos acerca da mamografia, promovendo a compreensão sobre o surgimento da mamografia, bem como aspectos como formação e apresentação da imagem, anatomia e fisiologia da mama, e a fisiopatologia do câncer de mama.

2.1.1 Contextualização

De acordo com Espadaro *et al.* (2018), o físico alemão Wilhelm Conrad Roentgen, em 1895, descobriu os raios-X mediante experiências com ampolas de Hittorf e Crookes, que consistiam em um tubo de vidro com condutor metálico interno que ao ser aquecido emitia elétrons na direção de outros condutos, esses raios de elétrons receberam o nome de raios catódicos. Ainda segundo os autores, junto ao tubo havia uma placa de platinocianeto de bário, que ao acionar o tubo emitia luminosidade que persistia mesmo quando colocada um livro e uma placa de alumínio entre o tubo e a placa.

Em uma experiência realizada com sua esposa no ano 1895, Wilhelm Conrad Roentgen imobilizou por alguns minutos a mão da mesma na trajetória dos raios entre o tubo e a placa, observando assim a imagem da mão, de modo que a sombra dos ossos e do anel que ela usava foi revelada após o processamento fotográfico da placa, sendo considerada a primeira radiografia da história (MARTINS, 2005).

Já o cirurgião alemão Albert Salomon, em 1913, estudou a aplicação da radiologia em doenças de mamas, utilizando-se da radiografia em peças cirúrgicas obtidas de operações de mastectomia, nas quais se constatou microcalcificações (ESPADARO *et al.*, 2018). Ainda de acordo com os autores, dezessete anos depois, em 1930, o médico radiologista americano Stafford Warren utilizou os raios-X para desenvolver uma técnica que produzia imagens estereoscópicas dos seios, assim, realizando a primeira mamografia em um paciente.

Desse modo, diversas descobertas e melhorias foram sendo realizadas ao longo dos anos, sendo elas:

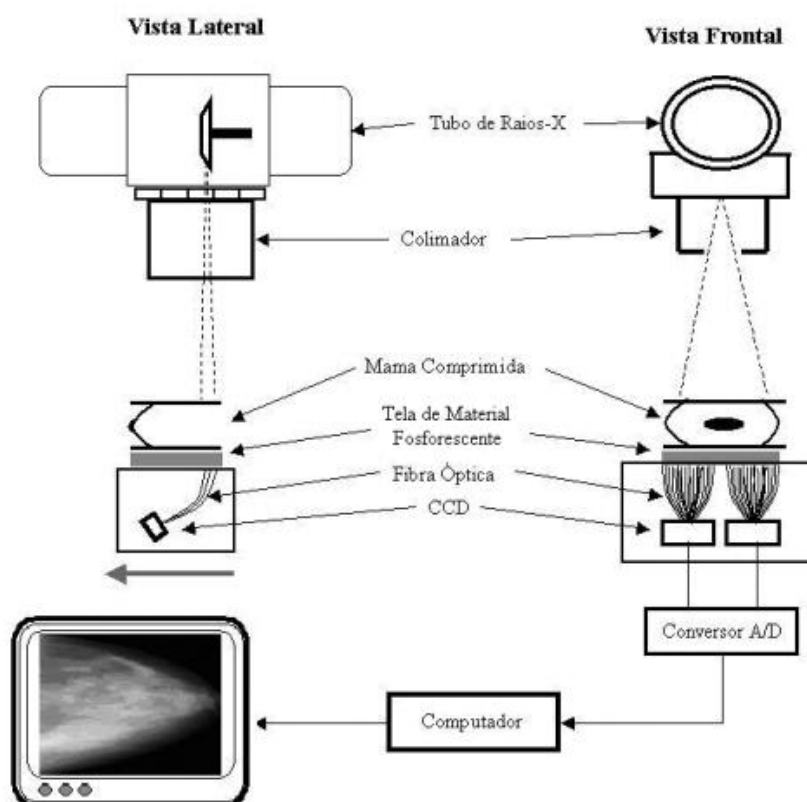
- Na década de 1950, onde o médico radiologista uruguaio Raul Leborgne realizou descobertas relevantes que indicava alterações de acordo com as posições do corpo nas imagens, enfatizando a necessidade de melhor qualidade para haver um diferencial no diagnóstico de calcificações malignas e benignas (LEBORGNE, 1951)
- Na década de 1960, Howard e Gould apresentaram uma técnica denominada xeromamografia que proporcionava o aprimoramento das imagens obtidas naquela época (KALAF, 2014).
- Na década de 1960, Charles Gross, especificamente em 1965, desenvolveu a primeira unidade dedicada à mamografia, equipamento este que possuía um tubo de raios-X de molibdênio com 0,7 mm de ponto focal, que proporcionava um elevado contraste diferencial entre a microcalcificações, parênquima e gordura (KALAF, 2014).
- Em 1970, cinco anos após o desenvolvimento da primeira unidade dedicada à mamografia, Price e Butler, utilizaram-se de écrans de alta definição e filmes industriais, obtendo grande sucesso na redução de radiação (KALAF, 2014).
- Da década de 1980, os sistemas que faziam uso de xeromamografia e filme sem tela, foram substituídos por uma mamografia que apresentava sistema filme-tela, que se tornou a técnica predominante (HAUS, 1993).
- A partir dos anos 2000, o equipamento de mamografia digital de aquisição direta, Senographe 2000 D é aprovado pela *Food and Drug Administration* (FDA), o qual é composto por um gerador de raios-X com características similar ao equipamento convencional, possuindo como diferença a introdução de um controlador computadorizado com controle automatizado de qualidade, e a substituição do sistema filme/écran por um detector eletrônico altamente diferenciado e eficaz da absorção do feixe de raios-X (KALAF, 2014).

Sendo assim cabe destacar o que aponta Espadaro *et al.* (2018), para os quais existem dois processos utilizados para realização da mamografia: o convencional que utiliza a tela-filme intensificadora; e o digital. Mahesh (2004) afirma que o convencional apresenta como principais benefícios o baixo custo e a durabilidade do armazenamento das imagens por meio do filme, enquanto o digital apresenta uma melhor qualidade de imagem, proporcionando maior facilidade e eficiência no diagnóstico de patologias mamárias.

2.1.2 Formação e apresentação da imagem

De acordo com Santos (2002) o mamógrafo digital é um aparelho similar ao convencional, possuindo os mesmos elementos como tubo de raios-X, dispositivo de compressão, colimadores, dentre outros, com exceção do sistema de registro, em que o filme e o écran são substituídos por detectores sensíveis aos raios-x, conforme mostrado na Figura 1.


Figura 1 — Esquema simplificado de um aparelho de mamografia digital



Fonte: Santos (2002).

A aquisição da imagem de cada mama pode ser feita de dois pontos de vista, sendo o Crânio Caudal (CC) e Médio-Lateral Oblíqua (MLO) (SILVA, 2005). De acordo com Góis (2006) a incidência MLO proporciona uma melhor forma de mostrar toda a mama em uma única imagem, porém é necessário que o posicionamento do receptor de imagem do equipamento esteja paralelo ao plano muscular, e assim, mostrando o máximo possível do tecido mamário e axilar, enquanto que a CC complementa a MLO. Na Figura 2, são apresentadas as duas incidências, CC e MLO.

**Figura 2 — Imagem referente a mama esquerda e direita com incidência CC (a).
Imagem referente a mama esquerda e direita MLO (b)**
(a) (b)



Fonte: Adaptado de Santos (2002).

A imagem na mamografia digital é formada como uma matriz bidimensional de elementos de imagens tratados de *pixels* de tamanho fixo de $40\mu m$ a $100\mu m$, assim, considera-se a mamografia digital como uma representação do padrão de transmissão dos raios-X através da mama a partir de uma matriz de *pixels* de imagem (INCA, 2019).

De acordo com o INCA (2019), cada *pixel* contém um valor que representa o brilho no respectivo ponto capturado na cena, extraído a partir da medida de intensidade dos raios-x em cada ponto da cena que é representado por esse *pixel*. Ainda de acordo com o INCA (2019), a intensidade dos raios-X em cada *pixel* da imagem é convertida, por um conversor analógico-digital, em um número finito (2^n) de níveis, onde o n trata-se do número de *bits* em que a imagem será digitalizada, normalmente de 12 a 14 bits, obtendo de 4906 a 16384 níveis de cinza ou de intensidade, respectivamente.

Segundo Santos (2002), o sinal armazenado, para toda a faixa de intensidade, é equivalente à intensidade da radiação que atinge os detectores, proporcionando à imagem digital uma maior precisão na reflexão do contraste subjetivo contida nas estruturas internas. Hemminger *et al.* (1999) afirmam que a imagem pode ser visualizada em um monitor de alta resolução, bem como a partir da impressão da imagem digital em filme mamográfico especial após a detecção e o processamento da imagem realizado pelo computador.

De acordo com o INCA (2019), após o armazenamento da imagem, pode-se apresentar para interpretação com contraste independente das características do detector, assim como pode ser ajustado pelo médico interpretador.

2.1.4 Anatomia e Fisiologia da Mama


A mama é uma glândula sudorípara modificada, coberta por tecido subcutâneo e pele, cujo desenvolvimento se inicia precocemente na vida embrionária (MENKE, 2007). Sua constituição é dada por parte glandular, gordura e elementos fibrosos (INCA, 2019).

De acordo com o INCA (2019), a glândula é a parte nobre chamada também de parênquima, constituída por lobos e ductos que apesar de serem presentes não são individualizados na mamografia, já a gordura envolve toda a mama, sendo dividida em duas camadas, uma adiposa anterior e outra adiposa posterior, enquanto os elementos fibrosos sustentam a mama envolvendo e atravessando a glândula.

A mama é envolvida por fâscias, as quais são definidas por Schleip, Jager e Klingler (2012) como tecidos colágenos fibrosos que fazem parte de um sistema de transmissão de força tensional de topo o corpo humano. Nesse sentido, a fâscia peitoral superficial é contínua com a fâscia abdominal de Camper e recobre toda a mama (PASSOS, 2017). Ainda de acordo com o autor, a fâscia posterior fica sobre a fâscia peitoral, cobrindo os músculos serrátil anterior e o peitoral maior. Segundo Menke (2007), a fâscia superficial possui dois folhetos, anterior e posterior, que são unidos por bandas fibrosas chamadas de ligamentos de cooper, ligamentos estes que por estarem unidos as fâscias superficiais e músculo grande peitoral, e com a derme, são responsáveis pela retração de pele quando estão comprometidos por tumor ou fibrose peritumoral, compondo ainda a sustentação natural da mama.

Em cada mama, externamente, a sua região central apresenta uma aréola e uma papila, onde na papila mamária exterioriza de 15 a 20 orifícios ductais, que correspondem às vias de drenagem das unidades funcionais, chamados de lobos mamários (INCA, 2002). Ainda de acordo com o INCA (2002), a mama divide-se em 15 a 20 lobos mamários independentes, que são separados por tecido fibroso, de modo que cada um possui a sua via de drenagem, que converge para a papila por meio do sistema ductal. Na Figura 3, é apresentada a anatomia da mama.

Figura 3 — Anatomia da mama



Fonte: Menke *et al.* (2007).

De acordo com Santos (2002) a mama se constitui basicamente de:

- Ácino - menor parte da glândula que tem por função a produção de leite durante a lactação;
- Lóbulo mamário - conjunto de ácinos;
- Lobo mamário - conjunto de lóbulos mamários que se ligam a papila por meio de um ducto;
- Ductos mamários - possuem de 15 a 20 canais, sendo responsável por conduzir o leite até a papila;
- Tecido glandular- conjunto de lobos e ductos;
- Papila - protuberância elástica onde desembocam os ductos mamários;
- Aréola - estrutura central da mama onde se projeta a papila;
- Tecido adiposo - o restante da mama é preenchido por tecido gorduroso e adiposo, onde a quantidade varia de acordo com a idade, características físicas e estado nutricional da mulher.

2.1.5 Fisiopatologia do câncer de mama

A expressão câncer de mama refere-se a uma doença originada quando as células da mama se dividem e multiplicam-se de forma desordenada, originando uma neoplasia, ou seja, proliferação anormal de células (ROCHA, 2014).

Há duas formas de tumores, sendo benignos e malignos, de forma que trata-se de tumor chamado de maligno, quando as células do tecido possuem a capacidade de gerar metástases, em outras palavras, possui a capacidade de espalhar-se para outras partes do corpo. Dessa forma, essas células ao entrarem na circulação sanguínea, podem chegar a outras regiões do corpo, obtendo a possibilidade de invadir tecidos e órgãos e originar novos tumores e, por consequência, levar uma pessoa a morte (SILVA, 2005).

Ao contrário dos malignos, os tumores tratados como benignos, não possuem a capacidade de gerar metástases, como também não se espalham por outros órgãos, possuindo um crescimento mais lento e não ultrapassam um certo tamanho (SILVA, 2005).

De acordo com INCA (2002), a formação do câncer ou carcinogênese, é geralmente lenta, podendo levar vários anos para que uma célula prolifere e origine um tumor palpável. Esse processo possui diversos estágios, sendo:

- Estágio de iniciação - onde os genes sofrem ação de fatores cancerígenos;
- Estágio de promoção - onde os agentes oncopromotores atuam na célula já alterada; e
- Estágio de progressão - caracterizada pela multiplicação descontrolada e irreversível da célula.

Rocha (2014) afirma que o tempo médio para ocorrer a duplicação celular no câncer de mama é de 100 dias, período no qual o tumor atinge 1 cm de diâmetro, já podendo ser palpável e possui aproximadamente 1 bilhão de células, que é o resultado de 30 duplicações celulares

Estima-se que o tumor de mama duplique de tamanho de 3 a 4 meses, assim, no início da fase subclínica, ou seja, quando ainda encontra-se impalpável, possui a impressão do crescimento ser lento pois as dimensões das células são mínimas, porém, após o tumor se tornar palpável, a duplicação é facilmente perceptível, e caso não seja tratado, o tumor pode desenvolver metástase (ROCHA, 2014).

Percebe-se que tanto na formação do tumor benigno quanto do tumor maligno, o crescimento celular forma uma massa, cuja identificação em estágio inicial pode ajudar na cura da doença (SILVA, 2005). O autor ainda afirma que a identificação dessas massas pelo

especialista recebe alguns nomes, como: lesão na mama, massa mamária ou nódulo não palpável.

De acordo com Moore, Dalley e Agur (2014) para localização anatômica de tumores, nódulos ou cistos, a superfície da mama deve ser dividida em quatro quadrantes, sendo o Quadrante Superior Externo (QSE), Quadrante Superior Interno (QSI), Quadrante Inferior Externo (QIE) e Quadrante Inferior Interno (QII). Na Figura 4, é apresentado os quadrantes da mama, em uma mama direita.

Figura 4 — Quadrantes da mama




Fonte: Bontrager (2003).

Segundo Porto (2010) as principais anomalias da mama são os nódulos (massas densas) e as microcalcificações, estruturas estas que devem ser descritas de forma detalhada descrevendo qual o tipo da estrutura, sua forma, o tamanho, o contorno, e a localização e a posição no quadrante ou em uma região.

Os nódulos são aglomerados de células, que ao serem unidas possuem uma densidade maior do que os tecidos que os envolve (ROCHA, 2014). Ribeiro (2013) afirma que a percepção mamográfica dos nódulos depende da densidade do tecido da mama, e em mamas densas os nódulos podem ser parcialmente ou totalmente obscurecidos, devido à similaridade de sua densidade com a densidade dos tecidos circundantes. É apresentado na Figura 5, exemplos de diagnóstico em mamografia.

Assim, na Figura 5, é apresentada uma imagem que não contém nódulos presentes (5a), uma imagem contendo nódulo benigno (5b) e, por fim, uma imagem que contém um nódulo maligno (5c).

Figura 5 — Imagens de mamografia com três tipos de diagnósticos. (a) mamografia saudável. (b) mamografia com nódulo benigno. (c) mamografia com nódulo maligno.



Fonte: Suckling *et al.* (1994).

2.2 Análise de Textura

Nos tópicos seguintes, busca-se apresentar conceitos acerca da análise de textura, promovendo a compreensão desde os fundamentos de textura, como também, da matriz de co-ocorrência e os descritores de textura de Haralick.

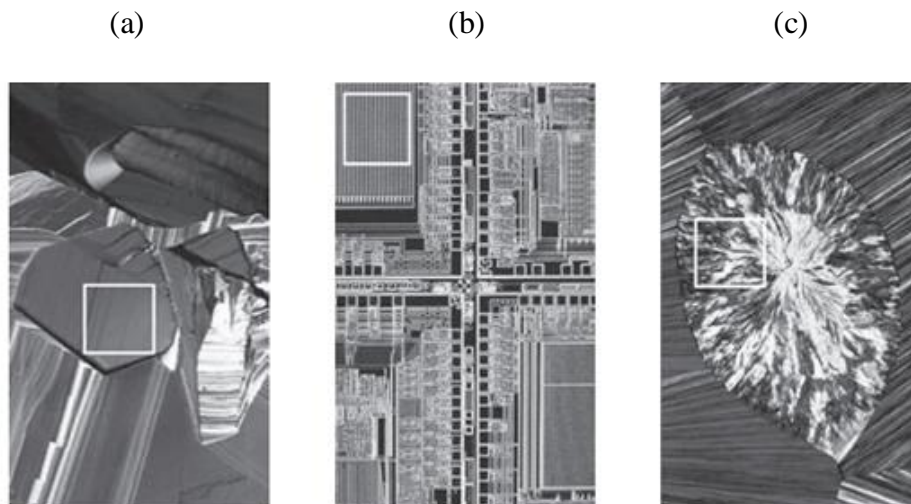
2.2.1 Contextualização

A compreensão e interpretação da textura é uma parte fundamental da percepção visual humana, podendo ser utilizada efetivamente para caracterizar diferentes regiões de imagens (JIAN; LIU; GUO, 2009). Enquanto que a percepção humana consegue distinguir facilmente regiões com valores similares de cinza ou cor em objetos, como também explicar variações causadas pela iluminação e alterações pela sobreposição de objetos, a presença de textura é de grande complexidade quando analisados a partir de uma perspectiva de visão computacional (PARKER, 2010).

Apesar disso, a textura assume um papel importante na análise de imagens, pois na maioria das vezes as imagens podem ser consideradas como uma composição de diversas regiões com texturas diferentes (KASHYAP; EOM, 1989). Com isso, diversas pesquisas foram propostas nos últimos anos para classificar imagens utilizando propriedades e características de textura, como por exemplo: Jian, Liu e Guo (2009), Freitas (2016), Ghongade e Wakde (2017).

Gonzalez e Woods (2010) afirmam que a quantificação da textura é uma abordagem importante para a descrição de regiões. Ainda segundo os autores, apesar de não haver uma definição formal, entende-se intuitivamente que a textura trata-se de propriedades que fornecem medidas de características de uma imagem, tais como suavidade, regularidade e rugosidade, conforme é mostrada na Figura 6.

Figura 6 — Os quadros brancos sobrepostos nas imagens mostram as propriedades de regiões suaves (a), regulares (b) e rugosas (c)



Fonte: Gonzalez e Woods (2010).

Desse modo, o processamento de imagens utiliza de três principais abordagens para descrever a textura (GONZALEZ; WOODS, 2010):

- Estatística: Produzem caracterizações das texturas como suave, rugosa, granuladas, dentre outras;
- Estrutural: Trabalham com arranjos de primitivas de imagens, como por exemplo, a descrição baseada em linhas paralelas espaçadas regularmente. Rocha (2014) colabora afirmando que nesta abordagem a textura é tratada como um conjunto de sub-padrões espaciais na imagem com arranjos espaciais repetitivos regulares; e,
- Espectral: Baseia-se em propriedades do espectro de Fourier, sendo utilizadas principalmente para detectar a periodicidade global em uma imagem pela identificação de picos de alta energia no espectro.

De acordo com Bueno (2001), a análise de textura pode estabelecer a conectividade que trata do relacionamento de vizinhança dos elementos de textura e o posicionamento em relação aos demais elementos, a densidade, que trata do número de elementos por unidade espacial e, por fim a homogeneidade, que refere-se a regularidade.

Freitas (2016) afirma que essas propriedades (conectividade, densidade e homogeneidade) são úteis para diversas etapas de um sistema de visão computacional, etapas essas que podem ser descritas em:

- Segmentação: divisão de uma imagem em regiões com o mesmo perfil de textura;
- Descrição: extração de características baseada na quantificação do conteúdo textural para diferenciação entre classes de objetos;
- Classificação: rotulação de uma região com determinada textura com base em exemplos de texturas conhecidas;
- Identificação de formas: empregar a informação de textura para derivar a geometria de uma superfície tridimensional; e,
- Réplica: descrever uma textura visando sua reprodução.

Nessa perspectiva, a distribuição dos níveis de cinza dos *pixels* pode ser caracterizada por medidas de diversas propriedades estatísticas (média, variância, desvio padrão, dentre outras), tais medidas estatísticas dependem somente da intensidade do nível de cinza de cada *pixel*, características que as tornam sensíveis, como por exemplo, variações monotônicas nos tons de cinza (ROCHA, 2014). O autor ainda afirma que para evitar problemas dessa natureza considera-se relações dependentes das transições de níveis de cinza entre dois ou mais *pixels* em uma vizinhança, onde utiliza-se a matriz de co-ocorrência para adquirir estas informações.


Dessa forma, pesquisas nas quais se utiliza a abordagem estatística, justificam tal abordagem pela possibilidade do uso de técnicas e métodos que relacionam as medidas de textura à impressão de propriedades como suavidade e rugosidade, dentre outras, além da extração de características de texturas a partir da matriz de co-ocorrência ser um dos métodos mais utilizados desta abordagem (SCHWARTZ; PEDRINI, 2005).

2.2.2 Matriz de Co-ocorrência de Tons de Cinza

Haralick, Shanmugam e Dinstein em 1973, descreveram a matriz de co-ocorrência de tons de cinza (GLCM - *Gray Level Co-Occurrence Matrix*) baseando-se na realização de uma varredura na imagem, analisando a frequência em que dois *pixels* de uma vizinhança ocorrem, considerando uma distância d e uma direção θ (VENTURA, 2009). O autor ainda afirma que na matriz de co-ocorrência $P(i, j)$ é levado em consideração dois *pixels* por vez, onde i é chamado de *pixel* referência e o j de *pixel* vizinho.

Trata-se o d como a distância em *pixel*, entre um *pixel* com tom de cinza i e um *pixel* com tom de cinza j . A Figura 7, apresenta uma matriz de níveis de cinza i e j , com vizinhança $d = 4$, alinhados na direção $\theta = 0$.


Figura 7 — Exemplo de uma co-ocorrência dos níveis de cinza, em relação à distância



Fonte: Ventura (2009).

O θ refere-se ao ângulo em que o *pixel* de nível de cinza i relaciona-se com o *pixel* de nível de cinza j dentro da vizinhança analisada, onde Haralick, Shanmugam e Dinstein (1973) propõe 4 ângulos, sendo 0° , 45° , 90° e 135° , como apresentado na Figura 8.

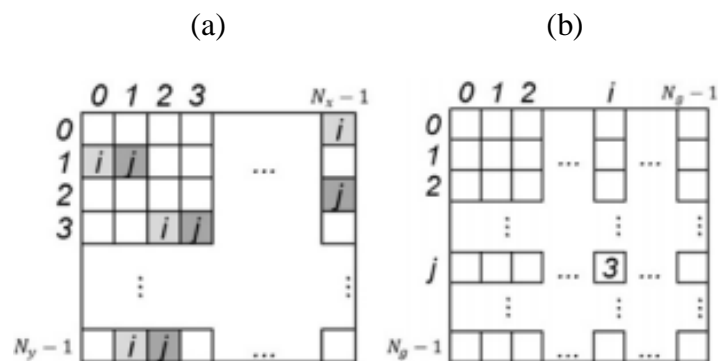
Figura 8 — Ângulos para cálculo da GLCM alinhados na direção $\theta = 0^\circ$, $\theta = 45^\circ$, $\theta = 90^\circ$ e $\theta = 135^\circ$



Fonte: Adaptado de Haralick, Shanmugam e Dinstein (1973).

A matriz de co-ocorrência possui o número de linhas e colunas proporcional a quantidade de tons de cinzas contidos na textura, sem depender das dimensões textural da imagem, fato este que acarreta perda do relacionamento espacial contida nessa textura (SCHWARTZ, 2005).

Figura 9 — (a) Imagem $N_x \times N_y$. (b) Matriz de co-ocorrência da imagem ($d = 1$, $\theta = 0^\circ$)




Fonte: Freitas (2016).

Na figura 9 é apresentada a formação de uma matriz de co-ocorrência com distância $d=1$ e o ângulo para análise da vizinhança $\theta=0$. A imagem que está sendo analisada é formada por $N_x \times N_y$ com intervalo de níveis de cinza de 0 a N_g . A matriz GLCM é formada por $N_g \times N_g$, onde cada célula é estabelecido por $P(i, j, d, \theta)$ como mostrado por Haralick, Shanmugam e Dinstein (1973). Em que:

- N_x é a quantidade de *pixels* na horizontal (Quantidade de colunas);
- N_y a quantidade de *pixels* na vertical (Quantidade de linhas); e
- N_g o número de tons de cinza.

Após determinado o número de ocorrências de cada uma das transições de níveis de cinza da textura, acrescenta-se o valor de $P(i, j)$ na i -ésima linha e j -ésima coluna da matriz, com isso obtém-se a matriz de co-ocorrência (SCHWARTZ, 2005). Na Figura 10 é apresentado um exemplo de uma GLCM com $N_g=8$, $d=1$ e $\theta=0$.

Figura 10 — Composição de uma GLCM (b) a partir de uma imagem hipotética (a)



Fonte: Gonzalez e Woods (2010).

De acordo com Schwartz (2005), apesar da matriz de co-ocorrência ser formada pelo número de transições que ocorrem entre os níveis de cinza, as características de texturas são obtidas a partir de outra representação desta matriz, chamado de representação normalizada, em que a GLCM é convertida em uma tabela de probabilidade.

Ainda conforme o autor, esta normalização se dá pela divisão de cada índice da GLCM pelo somatório de todos os valores contidos na matriz, como mostrado na Equação 1.

$$P(i, j) = \frac{P(i, j)}{\sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} P(i, j)} \quad (1)$$

Onde:

- P é o valor do elemento (i, j) na GLCM;
- i e j são os índices das linhas e das colunas, respectivamente;
- $P(i, j)$ é a probabilidade para o elemento $P(i, j)$ na matriz; e
- N_g é o número de linhas ou colunas na matriz.

Pedrini e Schwartz (2008) exemplificam o processo do cálculo de obtenção (Figura 11(b)) e normalização (Figura 11(c)) de uma matriz GLCM a partir de uma imagem hipotética (Figura 11(a)), na qual utiliza-se $N_g = 4$, $d = 1$ e $\theta = 0$;


Figura 11 — Exemplo de uma imagem hipotética (a) e o processo de cálculo (b) e normalização (c) de matriz de co-ocorrência

(a)					(b)					(c)				
3	2	0	1	0		0	1	2	3		0	1	2	3
1	2	1	3	0	0	3	2	1	1	0	0.15	0.10	0.05	0.05
3	1	0	2	3	1	2	0	2	1	1	0.10	0.00	0.10	0.05
1	2	3	0	3	2	1	1	0	2	2	0.05	0.05	0.00	0.10
0	0	0	0	1	3	2	1	1	0	3	0.10	0.05	0.05	0.00

Fonte: Pedrini e Schwartz (2008).

Gonzalez e Woods (2009), realizaram um experimento com três imagens com padrões de *pixels* aleatórios (Figura 12(a)), horizontalmente periódicos (seno) (Figura 12(b)) e mistos (Figura 12(c)), onde cada imagem possui dimensões de 263 x 800 *pixels*.

Figura 12 — Padrões de imagens aleatórios (a), periódicos (b) e mistos (c)




Fonte: Adaptado de Gonzalez e Woods (2010).

Foram criadas e plotadas GLCM denominadas G1, G2 e G3 para cada padrão de textura considerando $N_g = 256$, $d = 1$ e $\theta = 0$. Após cada GLCM normalizada ser plotada observa-se que

os valores altos tendem a ter níveis de cinza mais claros, enquanto que os valores baixos tendem a tons de cinza mais escuros. Como apresentado na Figura 13.

Figura 13 — Matrizes de co-ocorrência 256×256 , (a) G1, (b) G2 e (c) G3



Fonte: Gonzalez e Woods (2010).

De acordo com Gonzalez e Woods (2010), a Figura 13(b) é a mais interessante, pois mostra a simetria sobre a diagonal principal e que a diferença de valor entre os *pixels* adjacentes horizontais em uma onda senoidal horizontal são relativamente pequenos, o que causa a escassez de *pixels* diferentes de zero na matriz G2.

A GLCM G3 mostrada na Figura 13(c) é tratada como a mais complexa, pois os valores de contagem altos também são agrupados ao longo da diagonal principal, porém diferentemente da matriz G2 a sua distribuição é mais densa, o que sugere que a imagem possui uma variação rica em valores de intensidade, mas quase não há grandes variações de intensidade entre os *pixels* adjacentes (GONZALEZ; WOODS, 2010).

Freitas (2016) afirma que para sistemas computacionais é interessante que a análise seja quantitativa, de forma que possuam dados matemáticos que possam, com uma certa exatidão, representar a textura que os originou de forma numérica. Isto porque, todas as análises realizadas anteriormente, são análises qualitativas, que a partir das observações trazem apenas respostas conceituais (GONZALEZ; WOODS, 2010).

Nessa perspectiva, para representar de forma quantitativa padrões de textura, Haralick, Shanmugam e Dinstein (1973) propuseram 14 medidas estatísticas calculadas a partir da matriz de co-ocorrência normalizada.

2.2.3 Descritores de Haralick

Haralick, Shanmugam e Dinstein (1973) propuseram 14 métricas para análise de textura de imagens digitais, a partir de sua GLCM, denominadas de descritores de Haralick. Apesar

dessas medidas serem antigas, são a base para a maioria dos trabalhos realizados nessa área (SHARMA, 2001). Tais métricas, são obtidas por cálculos de domínio espacial e na abordagem de segunda ordem, baseando-se na premissa de que toda a informação de textura de uma imagem está contida total ou parcialmente em relações espaciais entre os seus níveis de cinza (FREITAS, 2016).

Rennó (2004) afirma que a principal desvantagem do uso de métricas baseadas na GLCM é a grande exigência de memória e tempo computacional, pois para uma imagem de 8 *bits* (256 tons de cinza), a GLCM é composta por 65536 elementos, sendo muito desses elementos com valores nulos.

Apesar desta desvantagem, os descritores de Haralick tem se mostrado eficientes para análise e classificação de imagens, sendo capazes de diferenciar uma região da imagem de outra, onde mostra-se ser uma assinatura de padrões definidos pela região em estudo (FERNANDES; ASSIS; LIMA, 2010).

Desse modo, as medidas de características chamadas de descritores de Haralick, apresentadas por Haralick, Shanmugam e Dinstein (1973) em um artigo descrevendo os métodos matemáticos que permitem a extração de 14 características de textura a partir de sua GLCM, são apresentadas e definidas pelas equações f_1 (Equação 2) à f_{14} (Equação 23).

2.2.3.1 Segundo Momento Angular

O Segundo Momento Angular ou ASM (*Angular Second Moment*) mede a uniformidade de uma textura, onde nas texturas ásperas, só apresentam valores diferentes de zero em poucos elementos da matriz GLCM normalizada, e quando ocorrem, são próximos de um, assim, este descritor apresenta valores próximos de um, o máximo possível para esta medida (SCHWARTZ, 2005).

$$f_1 = \sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} p(i,j)^2 \quad (2)$$

Pode-se obter outro descritor de textura a partir do ASM, onde utiliza-se a raiz quadrada do ASM para obter o descritor Energia.

$$ENERGIA = \sqrt{ASM} \quad (3)$$

2.2.3.2 Contraste

De acordo com Oliveira (2010) a medida de textura Contraste representa a quantidade de variação local dos níveis de cinza em pares de *pixels*, onde a presença de um valor elevado pode indicar a presença de ruídos, bordas, ou até mesmo rugas nas imagens.

$$f_2 = \sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} p(i,j) \cdot (i-j)^2 \quad (4)$$

2.2.3.3 Correlação

Esta medida mede a dependência linear entre os níveis de cinza contidas na imagem analisada, em que trata-se os valores altos, próximos de um, como a existência de relação linear entre os pares de tons de cinza (SCHWARTZ, 2005).

$$f_3 = \sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} p(i,j) \cdot \frac{(i - \mu_i) \cdot (j - \mu_j)}{\delta_i \delta_j} \quad (5)$$

Segundo Freitas (2016) a Correlação possui um significado mais intuitivo para os valores reais calculados, pois quando os valores obtidos pelo descritor forem iguais a zero, os valores analisados são correlacionados e quando os valores obtidos forem iguais a um, os valores analisados são perfeitamente correlacionados.

2.2.3.4 Variância (soma dos quadrados) e desvio padrão

De acordo com Schwartz (2005) a variância quando calculada, apresenta valores altos quando os níveis de cinza desviam do nível de cinza médio, independentemente da localização dos elementos da matriz e de sua frequência espacial contida na textura analisada.

Hall-Beyer (2017) afirma que a variância na textura realiza a mesma tarefa que a estatística descritiva comum baseando-se na média e na dispersão dos dados em torno da média dos valores dentro da GLCM, porém a variância da GLCM trata especificamente das combinações do *pixel* de referência e o *pixel* vizinho, não se tratando da variância simples dos tons de cinza na imagem original.

$$f_4 = \delta_l^2 = \sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} p(i,j) \cdot (i - \mu_i)^2 \quad (6)$$

$$f_4 = \delta_j^2 = \sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} p(i, j) \cdot (i \cdot \mu_j)^2 \quad (7)$$

Hall-Beyer (2017) ainda afirma que as variâncias calculadas no sentido i e j retornam o mesmo resultado, uma vez que a GLCM é simétrica. Utilizando a raiz quadrada da variância, obtém-se o desvio padrão, sendo:

$$D_i = \delta_i = \sqrt{\delta_i^2} \quad (8)$$

$$D_j = \delta_j = \sqrt{\delta_j^2} \quad (9)$$

2.2.3.5 Homogeneidade ou momento da diferença inversa

Na equação 10, mostra a medida de Homogeneidade também conhecida como momento da diferença inversa ou IDM (*Inverse Difference Moment*). Este descritor apresenta correlação inversa com o descritor de contraste, onde a Homogeneidade assume valores altos quando a textura apresenta pequenas variações de tons de cinza entre os pares de *pixels* (SCHWARTZ, 2005).

Oliveira (2010) colabora dizendo que esta medida mede a suavidade das distribuições dos tons de cinza, pois quando o contraste é baixo o valor resultante a partir desta medida é alto.

$$f_5 = \sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} \frac{p(i, j)}{1 + (i - j)^2} \quad (10)$$

2.2.3.6 Soma das Médias

A soma da média ou AS (*Sum Average*), calcula a média da distribuição da soma dos tons de cinza analisados (OLIVEIRA, 2010), mostrada na equação seguinte:

$$f_6 = \sum_{i=2}^{2N_g} i \cdot p_{x+y}(i) \quad (11)$$

2.2.3.7 Soma da Variância

A medida Soma da Variância, mede a dispersão (em relação à média) da distribuição da soma dos tons de cinza de uma imagem (OLIVEIRA, 2010). Esta medida está descrita na equação 12.

$$f_7 = \sum_{i=2}^{2N_g} (i - f_8) \cdot p_{x+y}(i) \quad (12)$$

2.2.3.8 Entropia da Soma

O descritor Entropia da Soma ou SE (*Sum Entropy*) mede a desordem relacionada com a distribuição da soma dos tons de cinza da imagem analisada (OLIVEIRA, 2010).

$$f_8 = \sum_{i=2}^{2N_g-1} p_{x+y}(i) \cdot \log[p_{x+y}(i)] \quad (13)$$

Haralick, Shanmugam e Dinstein (1973) recomenda que uma constante positiva com o valor arbitrariamente pequeno seja adicionada ao logaritmando, tendo em vista que $P_{x+y}(i)$ pode resultar em um valor igual a zero, evita-se a expressão $\log(0)$, já que não existe resposta para esta expressão. Assim, temos $\log[P_{x+y}(i) + e]$ onde e é a constante escolhida.

2.2.3.9 Entropia

A medida Entropia, mede a desordem em uma imagem analisa, visto que, na imagem que apresenta textura uniforme, os valores resultantes tendem a ser muitos baixos, enquanto que para alcançar os valores máximos, os *pixels* na área de interesse têm que apresentar níveis de cinza com valores aleatórios (COSTA, 2009). O autor ainda afirma que esta medida apresenta correlação linear com a medida Segundo Momento Angular e não é correlacionada com a medida de correlação.

$$f_9 = - \sum_{i=0}^{N_g-1} \sum_{j=2}^{N_g-1} p(i, j) \cdot \log[p(i, j)] \quad (14)$$

Hall-Beyer (2017) demonstra por meios matemáticos que o valor máximo resultante do cálculo da entropia é 0,5.

2.2.3.10 Variância da Diferença

Esta medida, Variância da Diferença, também conhecida como DV (*Difference Variance*) é um descritor que mede a dispersão (em relação à média) da distribuição da diferença entre os tons de cinza da imagem analisada (OLIVEIRA, 2010).

$$f_{10} = \sum_{i=0}^{N_g-1} (i - \mu_{x-y})^2 p_{x-y}(i) \quad (15)$$

Tendo que:

$$\mu_{x-y} = \sum_{i=0}^{N_g-1} i \cdot p_{x-y}(i) \quad (16)$$

2.2.3.11 Entropia da Diferença

O descritor Entropia da Diferença de acordo com Oliveira (2010) mede a desordem relacionada com a distribuição da diferença dos tons de cinza da imagem analisada.

$$f_{11} = - \sum_{i=0}^{N_g-1} p_{x-y}(i) \cdot \log[p_{x-y}(i)] \quad (17)$$

2.2.3.12 Informações de Medidas de Correlação 1

O descritor Informações de Medidas de Correlação 1 é um indicador da correlação baseada nos pares de elementos e da entropia para elementos independentes contidos na imagem (FREITAS, 2016).

$$f_{12} = \frac{HXY - HXY1}{\max(HX, HY)} \quad (18)$$

Tendo que HX e HY são entropias de p_x e p_y , e

$$HXY = - \sum_{i=0}^{N_g-1} \sum_{j=2}^{N_g-1} p(i, j) \cdot \log[p(i, j)] \quad (19)$$

$$HXY1 = - \sum_{i=0}^{N_g-1} \sum_{j=2}^{N_g-1} p(i, j) \cdot \log[p_x(i) \cdot p_y(j)] \quad (20)$$

2.2.3.13 Informações de Medidas de Correlação 2

Segundo Fernandes, Barbosa e Patrocínio (2016) o descritor Informações de Medidas de Correlação 2 é uma medida de correlação baseada na similaridade entre os pares de elementos da imagem e as entropias de elementos independentes contidos na imagem.

$$f_{13} = \sqrt{1 - e^{-2(HXY2 - HXY)}} \quad (21)$$

Tendo que:

$$HXY2 = - \sum_{i=0}^{N_g} \sum_{j=2}^{N_g} p_x(i) p_y(j) \cdot \log[p_x(i) \cdot p_y(j)] \quad (22)$$

2.2.3.14 Coeficiente de Correlação Máximo

De acordo com Fernandes, Barbosa e Patrocínio (2016) o descritor de Coeficiente de Correlação Máximo indica a não homogeneidade da distribuição dos tons de cinza da imagem.

$$f_{14} = h(Q)^{\frac{1}{2}} \quad (23)$$

Tendo que $h(Q)$ é o segundo maior autovalor de Q , e

$$Q(i, j) = \sum_{k=0}^{N_g-1} \frac{p(i, k) \cdot p(j, k)}{p_x(i) \cdot p_y(k)} \quad (24)$$

2.4 Trabalhos relacionados

Diversos sistemas CAD foram propostos nos últimos anos com o intuito de apresentar métodos de visão computacional para auxiliar no diagnóstico médico com diferentes propósitos de segmentação e classificação, como por exemplo:

- Segmentação: Áreas de AVCi (FREITAS, 2016), lesões de pele (PIRNOG et al, 2015).
- Classificação: Câncer de pulmão (ALAM; ALAM; HOSSAN, 2018), lesões adrenais (LI, 2017).

Nesta perspectiva, foram surgindo cada vez mais metodologias para processamento de imagens médicas que podem ser encontradas na literatura, dentre elas, as que possuem relação com este trabalho.

2.4.1 Trabalho de Radovic et al.

No trabalho de Radovic *et al.* (2013) objetiva-se classificar imagens normais (sem tumor) e anormais (com tumor), empregando uma técnica para remover o músculo peitoral mamário subtraindo a imagem original com a imagem cujo músculo foi identificado. Para extração de características utilizou-se a matriz GLCM com vinte descritores de textura, sendo treze descritores proposto por Haralick, cinco por Soh e dois por Claus.

A partir das texturas obtidas foram utilizados 7 classificadores diferentes, sendo eles: máquina vetorial de suporte, classificador de bayes ingênuos, k vizinhos mais próximos, regressão logística, árvores de decisão, floresta aleatória e rede neural. Para validação, usou-se 322 imagens do banco mini-MIAS com a validação cruzada *leave-one-out*. Visando comparar a precisão dos classificadores, calculou-se a acurácia e a curva ROC.

A rede neural perceptron de múltiplas camadas foi o classificador com maior precisão obtendo 76% de acurácia e 0,788 na curva ROC. Pleiteando melhorar a classificação o algoritmo de Relevância Mínima de Redundância Mínima (*Minimum Redundancy Maximum Relevance* - MRMR) é aplicado, obtendo com o classificador árvores de decisão C4.5 79,33% de acurácia e 0,811 da curva ROC.

2.4.2 Trabalho de Gaike et al.

No trabalho proposto por Gaike *et al.* (2015) intitulado “*Clustering of breast cancer tumor using third order GLCM feature*” propõe-se uma metodologia para identificação e classificação de tumores malignos e benignos utilizando descritores de textura e o algoritmo de clusterização *k-means*.

Para tanto, criaram um banco de imagens de mamografia digital regional, obtendo a imagem de três locais, sendo eles: Chikitsa Radiology & Research Centre, Ahmednagar e Maharashtra. O banco contém 190 mamografias digitais cada uma revisada por radiologistas para identificação de anomalias. No método proposto, para remover o músculo peitoral, utilizou-se uma máscara binária com limiar local adaptativo e posteriormente operações morfológicas para remoção de artefatos e identificação do músculo peitoral. Com o músculo identificado, é subtraído a imagem original da imagem com o músculo identificado.

No que diz respeito ao aperfeiçoamento da imagem, empregou o filtro de Equalização de Histograma Adaptativa Limitada ao Contraste (*Contrast Limited Adaptive Histogram Equalization* - CLAHE) onde é dividido a imagem em regiões e aplicado a equalização do histograma em cada região. Com a utilização da equalização do histograma pode-se aumentar os ruídos e diminuir a qualidade da imagem, onde é resolvido obtendo-se um limite de expansão do contraste, limite esse sendo igual a 0,5. O limite obtido faz com que ao redistribuir cada histograma, a altura não ultrapasse o limite de 0,5. Tratando-se da extração de características, calculou-se a partir da GLCM de terceira ordem, histograma de intensidade são estatísticas de primeira ordem do nível de cinza (*Gray Level First Order Statistics* - GLFOS). Os descritores de primeira ordem foram a média, desvio padrão, curtose e assimetria.

Finalizada a obtenção de características, com o intuito de selecionar os melhores descritores, utilizou-se um algoritmo genético com todas as características. Assim, os melhores descritores selecionados pelo AG foram proeminência de cluster, energia, medida de informação de correlação, diferença inversa normalizada, assimetria e curtose. Para agrupar as características (maligno e benigno) usou-se o algoritmo de clusterização *k-means* obtendo um percentual de acerto de 81% nos tumores benignos e 93% nos tumores malignos.

2.4.3 Trabalho de Raghavendra et al.

Na pesquisa de Raghavendra *et al.* (2016), os autores propuseram um método automatizado para classificação de câncer de mama em 3 vertentes: normal (sem tumor), maligno e benigno. Utilizou-se para teste 230 imagens normais, 230 imagens com tumor benigno e 230 com tumor maligno da base de imagem *Digital Database for Screening Mammography* (DDSM).

No pré-processamento, para retirar os artefatos, foi aplicado o filtro média, de máscara 9x9 e binarizada utilizando o limiar global com o limiar de 0.1. Com a máscara binária obtida é aplicado novamente na imagem original a suavização por meio do filtro média, com máscara de 39x39 e binarizada com o limiar global de 0,5. Diante desse pré-processamento, todas as partes que não fazem parte da mama e o músculo peitoral são removidos das imagens. Para aprimoramento e extração de características nas imagens, empregou filtros morfológicos, usando elementos estruturantes em forma de disco de raio 3, resultando em uma dimensão 5x5.

Em busca de extrair as características, aplicou-se filtros de *wavelets* Gabor em toda a imagem filtrada com o objetivo de diferenciar claramente os tecidos normais e anormais por meio da obtenção de padrões de textura como linhas, bordas, manchas e áreas planas. Para reduzir o grande número de dados extraídos, uma vez que a grande quantidade de dados é difícil

de analisar, testou-se 5 métodos de redução de dimensionalidade sendo: *Principal Component Analysis* (PCA), *Kernel PCA* (KPCA), *Linear Discriminant Analysis* (LDA), *Neighborhood Preserving Embedding* (NPE) e *Locality Sensitive Discriminant Analysis* (LSDA).

Para classificação das imagens em normais, com tumor benigno e com tumor maligno foram utilizados 8 classificadores (Classificador de árvore de decisão, Classificador Discriminante, Classificador k vizinho mais próximo, Classificador *Naive Bayes*, Classificador de rede neural probabilística, Classificador Máquina de vetores de suporte, Classificador *AdaBoost* e Classificador Sugeno Difuso) com a estratégia de validação cruzada de 10 vezes, ou seja, a média de 10 experimentos repetidos é considerada como desempenho final para conseguir a sensibilidade, especificidade, Valor Preditivo Positivo (VPP) e a precisão.

Nos testes realizados, mostram que o classificador K- vizinhos mais próximos (*K-Nearest Neighbors* - KNN) e a técnica de redução de dimensionalidade são o que possui a melhor Precisão (98,69%), VPP (99,13%), Sensibilidade (99,34%) e Especificidade (98,26%). Logo, a metodologia proposta alcançou uma precisão média de 98,69% usando apenas 8 recursos significativos.

2.4.4 Trabalhos Perez et al.

Perez et al. (2017), apresentam em seu trabalho “*Mammogram classification using back-propagation neural network and texture feature descriptors*” um método automático para classificação de mamografia em normais (sem tumor), benigno e maligno por meio de rede neural e análise de textura aplicando os descritores de Haralick. Foram utilizadas 600 imagens do banco de imagens DDSM, sendo 200 imagens normais, 200 imagens benignas e 200 imagens malignas. Para extração de características foi usado 14 descritores de textura de Haralick calculados a partir da matriz GLCM.

A classificação dessas características de textura, o autor optou pela rede neural Perceptron de Múltiplas Camadas (*Multilayer Perceptron* - MLP) com o algoritmo de treinamento *back-propagation*. Para validação, empregou a validação cruzada e para avaliação do desempenho de classificação das classes normais, benignas e malignas aplicou-se a matriz de confusão. Desse modo, a metodologia alcançou uma taxa de precisão de classificação da validação cruzada *leave-one-out* e do conjunto de testes foi, em média, de 84,72%.

2.4.5 Trabalho de Ghongade e Wakde

Na pesquisa de Ghongade e Wakde (2017), apresenta uma metodologia para localização e classificação de tumores mamários a partir de imagens de mamografias digitais retiradas do banco de imagem MIASDB. Para melhoria das imagens, realizou-se no pré- -processamento a aplicação do filtro gaussiano para suavizar a imagem e reduzir os ruídos. Dessa maneira, é usada a equalização adaptativa do histograma com o intuito de melhorar o contraste da imagem. Para segmentação, é utilizado o método de Otsu. Com a imagem segmentada, é multiplicada a imagem original com a imagem cuja segmentação foi realizada, como processo de normalização.

Para extração de características, a matriz GLCM é aplicada para extrair os recursos de textura com os descritores de contraste, correlação, energia, homogeneidade, média, desvio padrão, entropia, variância, suavidade, curtose, assimetria e inverso do momento, bem como as características de forma como área, solidez, excentricidade, perímetro e comprimento do eixo principal.

Visando beneficiar a precisão da classificação e redução do tempo computacional é selecionado as características mais relevantes por meio do método de Seleção de Recurso Baseada em Correlação Rápida (*Fast Correlation based feature Selection* - FCBF). O FCBF é usado para selecionar as características de alta dimensão. Dos 17 descritores, apenas 7 foram selecionados. Para classificação, empregou a Floresta Aleatória (*Random Forest* - RF), onde a classificação é realizada enviando uma amostra para baixo em cada árvore e atribui o rótulo do nó terminal. Com isso, ao final, o voto de todas as árvores é contabilizado para realizar a classificação. Para avaliação do desempenho, é utilizado a matriz de confusão e a curva ROC com pontuação AUC. Ao final dos testes, o método proposto atingiu precisão de 97,32%, sensibilidade de 97,45%, especificidade de 98,13% e a curva ROC com AUC de 97,28%.

3 MATERIAIS E MÉTODOS

Nesta seção, busca-se apresentar a classificação da pesquisa, bem como os materiais utilizados e os métodos empregados para o desenvolvimento e testes.

3.1 Classificação da pesquisa

Pode-se classificar esta pesquisa quanto aos procedimentos lógicos como dedutiva, uma vez que busca esclarecer os procedimentos lógicos analisados no processo de investigação partindo do geral para o específico. De acordo com Gil (2008) o método dedutivo parte de princípios tratados como verdadeiros e indiscutíveis possibilitando chegar em virtude da lógica, em conclusões puramente formais.

Para desenvolvimento desta pesquisa, realizou-se uma pesquisa bibliográfica a fim de analisar teorias e propostas para fundamentação desta, bem como trabalhos com propostas semelhantes para verificar quais foram desenvolvidos nesta temática apresentada. Assim, para esta pesquisa utilizou-se dos seguintes descritores: métodos de visão computacional para segmentação de mamografias, segmentação de nódulos por meio de análise de textura e o método *k-means*. Para Gil (2008), a pesquisa bibliográfica é desenvolvida a partir de pesquisas e teorias já existentes, principalmente em materiais como livros e artigos científicos.

Quanto à natureza, esta pesquisa caracteriza-se como aplicada, que segundo Prodanov e Freitas (2013) tem por finalidade o desenvolvimento e aplicação prática de métodos para solução de um problema específico, proporcionando assim, a obtenção de conhecimento, tendo em vista que o desenvolvimento do método computacional proposto permite aos médicos um melhor diagnóstico, bem como melhorias na precisão da análise.

Do ponto de vista de seus objetivos, trata-se de uma pesquisa explicativa pois houve a necessidade de investigar e explicar determinados motivos e causas. Gil (2002, p. 43) afirma que “esse é o tipo de pesquisa que mais aprofunda o conhecimento da realidade, porque explica a razão, o porquê das coisas”.

Quanto aos procedimentos técnicos, classifica-se como uma pesquisa experimental, já que se determina a um objeto de estudo e as variáveis capazes de influenciá-lo, definindo formas de controle e observação dos efeitos nas quais a variável produz no objeto (PRODANOV; FREITAS, 2013). Neste caso, para esta pesquisa, foram determinados e analisados quais os métodos de visão computacional seriam capazes de segmentar os nódulos mamários.

Classifica-se quanto a forma da abordagem do problema como quantitativa, visto que considera o que pode ser quantificável, ou seja, traduzir opiniões e informações em números

para analisá-las e classificá-las, bem como a utilização de estatística, onde nesta pesquisa será analisado o percentual de classificação e de casos de sucesso (KAUARK; MANHÃES; MEDEIROS, 2010).

3.2 Materiais

Quanto aos materiais, a pesquisa fez uso da biblioteca *Opencv*, Linguagem C++ e IDE *Qt Creator*, Base de dados mini-MIAS, *software SPSS Statistics*, e o Classificador *k-means*.

3.2.1 Opencv

Como forma de utilizar recursos de visão computacional, utilizou-se a Biblioteca de Visão Computacional de Código Aberto (*Open Source Computer Vision Library*) - OpenCV, na sua versão 2.0. OpenCV é uma biblioteca multiplataforma que possui diversos recursos para desenvolvimento de *softwares* na área de visão computacional. Conta com diversos módulos para manipulação de imagens, reconhecimento de padrões e para aprendizado de máquinas. Esta biblioteca foi desenvolvida para realizar seus processamentos com eficiência computacional, implementada naturalmente em linguagem C/C++, contudo, também dá suporte à outras linguagens como Java e Python, dentre outras (BRADSKI; KAEHLER, 2008).

3.2.2 Linguagem C++

Para implementação do método proposto utilizou-se a Linguagem de programação C++, a qual suporta diversos tipos de paradigmas, como por exemplo orientação a objetos e programação estruturada (SCHILDT, 1996). O C++ é uma linguagem compilada, desta forma, após ser processado por um compilador, deverá ser executado diretamente pelo sistema operacional ou pelo processador. Escolheu-se utilizar a linguagem C++ por ser uma linguagem portátil, possuir as funcionalidades da Linguagem C e por permitir programar em baixo e alto nível (JAMSA; KLANDER, 1999). Considerou-se também para utilização desta linguagem, o fato de ter fácil integração com a biblioteca OpenCV.

3.2.3 IDE Qt Creator

Para o desenvolvimento, utilizou-se o IDE (*Integrated Development Environment* - Ambiente de Desenvolvimento Integrado) *Qt Creator*, versão 5.4, que possui diversos recursos e bibliotecas destinados ao desenvolvimento de sistemas em C++. Assim, definiu-se essa IDE por possuir uma interface simples e intuitiva, um editor de código com preenchimento

automático e realce de sintaxe (QT, 2019). Além disto, pode-se executar em máquinas com pouco poder de processamento, já que é bastante leve.

3.2.4 Base de imagens

Com a finalidade de avaliar o método proposto, utilizou-se a base de imagens Mini MIAS da Sociedade de Análise de Imagem Mamográfica, proposto por Suckling *et al.* (1994). A base é composta por 322 imagens de mamografias de extensão PGM, divididas em imagens com diagnóstico normais e doentes (tumor benigno e maligno) com dimensões 1024x1024. Cada imagem possui um laudo médico, contendo diversas informações referente ao diagnóstico, tendo como principais informações: a classe da anomalia presente, a gravidade, as coordenadas do centro e o raio em que a anomalia está contida.

Para esta pesquisa, devido ao tempo de processamento, usou-se 30 imagens de mamografias digitais, sendo 15 imagens diagnosticadas doentes (com presença de nódulos) e 15 imagens diagnosticadas normais (sem presença de nódulos).

3.2.5 SPSS Statistics

Utilizou-se para análise das distribuições dos dados o *software SPSS Statistics*[®] (IBM, 2019) em sua versão 25.0. O *software* possui uma biblioteca com uma vasta quantidade de recursos, como por exemplo: algoritmos de aprendizado de máquina, análise de texto e testes preditivos e de hipóteses, permitindo gerar relatórios e gráficos (IBM, 2019). Optou-se por usar o *SPSS statistics* por sua robustez e facilidade de uso.

3.2.6 O classificador

O método proposto baseia-se no agrupamento de cada *pixel* da imagem de mamografia a partir da análise da textura obtida através dos descritores de Haralick extraídos da GLCM. Este agrupamento se dar pela utilização do método de clusterização, *k-means*.

O método *k-means* trata-se de um algoritmo de aprendizado não-supervisionado de agrupamento de dados que não requer nenhum conhecimento prévio das classes que se desejam diferenciar (SOUTO JUNIOR, 2010). Assim, o *k-means* classifica os *pixels* da imagem em *k* grupos, tendo que, para cada um dos grupos em que a imagem foi dividida é atribuído um valor médio de níveis de cinza dos *pixels* que o compõem e representará (AGUIAR, 2017).

De acordo com Takahashi, Bedregal e Lyra (2005) este método busca diminuir a quantidade de tons de cinza em relação a imagem original para *k* tons de cinza, e a média dos

elementos ou *pixels* de cada grupo representa uma intensidade luminosa, assim, resultará em uma imagem com k níveis de cinza diferentes agrupados em k grupos.

O algoritmo *k-means* consiste basicamente em duas fases, enquanto que a primeira fase calcula o k centróide, a segunda fase, leva cada ponto ao cluster que tem o centróide mais próximo do respectivo ponto de dados (DHANACHANDRA; MANGLEM; CHANU, 2015). Ainda de acordo com os autores, existem diversos métodos para definir a distância do centróide mais próximo, sendo o mais utilizado, a distância euclidiana.

Dessa forma, considerando uma imagem com dimensões $X_p \times Y_p$, com o número de grupos k , $P(i,j)$ sendo os *pixels* de entrada, C_k o centróide do grupo e d a distância euclidiana. Abdul-Sanir, Mashor e Mohamed (2013) demonstram o funcionamento do algoritmo *k-means*:

1. Inicialização dos grupos e dos centros;
2. Realização do cálculo da distância euclidiana para cada *pixel* da imagem, cálculo este realizado entre os centroides e cada *pixel*, dada pela equação 3.1.

$$d = || P(i,j) - C_k || \quad (25)$$

3. Baseado no cálculo da distância euclidiana, define todos os *pixels* como pertencentes aos centroides mais próximos.
4. Com os *pixels* em seus grupos, realiza-se novamente o cálculo para nova posição dos centroides de acordo com a equação 3.2.

$$C_k = \frac{1}{k} \sum_{i \in C_k} \sum_{j \in C_k} P(i,j) \quad (26)$$

5. Repete-se os passos 2 e 4 até que os critérios de parada sejam satisfeitos, ao ponto que estes critérios podem ser tanto: a não modificação dos centroides, ou dos *pixels*, ou o atingimento do número máximo de iterações.

Desse modo, para esta pesquisa utilizou-se dez centroides, em que cada centróide representa um nível de cinza da imagem analisada, tendo como critério de parada: a não modificação dos centroides, ou a não modificação dos *pixels*, ou o atingimento de no máximo 40 interações, visto que a partir deste número de interações não se modificavam mais o resultado.

3.3 Métodos

Quanto aos métodos utilizados nesta pesquisa, estes dividem-se em três etapas, a metodologia para avaliação do potencial discriminatório dos descritores de Haralick que aborda

o processo de análise estatística dos descritores de Haralick, a metodologia para classificação e segmentação que trata das metodologias adotadas para pré-processamento, extração de atributos, classificação, segmentação e pós-processamento, e a metodologia para avaliação e interpretação que trata das formas de validação do método.

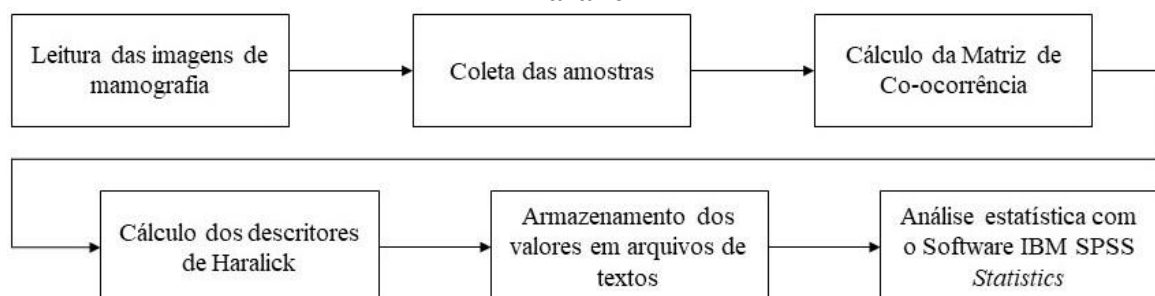
3.3.1 Metodologia para avaliação do potencial discriminatório dos descritores de Haralick

Para análise dos melhores descritores de Haralick, foram coletados manualmente 30 pontos de cada imagem com o clique do *mouse*, que representarão amostras dos tecidos normais e doentes, em que, nas imagens doentes são coletados pontos na região do centro e das bordas dos nódulos, enquanto que nas imagens normais, são coletados na região saudável de toda a mama. Assim, obtendo 30 amostras de cada uma das 30 imagens de mamografia digital, obtém-se 900 amostras ao total. Essas amostras são armazenadas em arquivos de texto com as suas respectivas coordenadas (x,y).

Para cada *pixel* referenciado pelas coordenadas do ponto é criada uma vizinhança, de matriz 9x9, da qual calcula-se a matriz GLCM normalizada obtendo os valores de textura através dos cálculos dos descritores de Haralick.

Com o intuito de avaliar possíveis diferenças estatísticas entre os grupos de regiões de texturas normais e texturas doentes, é realizado testes de hipóteses não paramétrico. O teste aplicado é o de duas amostras independentes, U de Mann-Whitney. Os testes estatísticos, realizados no software SPSS *statistics*, indicam diferenças significativas entre dois grupos se o nível de significância for menor ou igual que o nível de significância (ρ) aplicado no teste ($\rho < 0,01$). Na Figura 14, é apresentado o fluxograma com o processo da análise estatísticas.

Figura 14 — Fluxograma da fase de análise estatística dos melhores descritores de Haralick



Fonte: Elaborado pelo autor (2019).

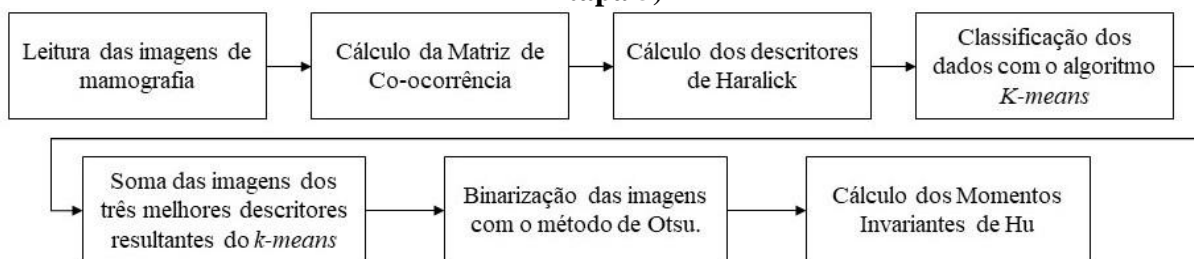
3.3.2 Metodologia para classificação e segmentação

Nas 5 etapas entendidas como essenciais para o sistema de visão computacional, adotadas como metodologia para classificação e segmentação, ocorrem um pré-processamento das imagens, a extração de características com os descritores de Haralick, a classificação da textura a partir do *k-means*, a segmentação das imagens geradas a partir do *k-means*, e por fim o pós-processamento.

Para o pré-processamento (Etapa 1), aplicou-se nas imagens de mamografia o realce negativo, bem como a utilização do realce exponencial, com o intuito de deixar o nódulo mais evidente. Para suavizar e reduzir os ruídos, aplicou-se um filtro passa baixa mediana com máscara de 15x15.

Na fase de extração de características (Etapa 2), é calculada a matriz GLCM normalizada da imagem de mamografia digital com uma vizinhança de matriz 9x9 de cada *pixel*. Após o cálculo da matriz de co-ocorrência normalizada, são calculados os descritores de Haralick. Assim, os valores dos descritores de Haralick são apresentados como entrada do método de *k-means* (Etapa 3), que agrupa os valores, gerando uma imagem em níveis de cinza de cada descritor. Na Figura 15, é apresentado um fluxograma da fase de classificação.

Figura 15 — Fluxograma da classificação e segmentação (Etapa 2, Etapa 3, Etapa 4 e Etapa 5)




Fonte: Elaborado pelo autor (2019).

Dessa forma, as imagens resultantes do *k-means*, tendo em vista os três melhores descritores analisados estatisticamente, são somadas com o objetivo de deixar as regiões em comuns mais escuras e as regiões que se diferem mais claras, podendo destacar o nódulo.

Com o intuito de garantir uma região melhor para a identificação, a imagem de saída do *k-means* é processada pela função de binarização, tratada como método de Otsu (OTSU, 1979), para determinação do limiar (Etapa 4). Na Figura 16 são ilustradas as etapas do processamento do método empregado para a identificação dos nódulos por meio do *k-means*.

Como forma de reduzir e eliminar falsos positivos provindos de regiões cuja textura se assemelha a regiões dos nódulos, é realizado um pós-processamento (Etapa 5). Para isso, analisa-se as regiões segmentadas, por meio dos momentos invariantes de Hu (HU, 1962) em que avalia-se algumas propriedades como cálculo dos centróides (coordenadas de centro de massa, x_c e y_c), as áreas (momento de ordem zero, m_{00}), e as formas como circularidade, convexidade e a taxa de inércia, de forma que após realizar essa filtragem, desconsideram-se áreas muito pequenas e muito grandes, bem como objetos que não sejam circulares ou em formas de elipses. O resultado do pós-processamento é apresentado na Figura 16(e).

Figura 16 — Etapas do processo de segmentação dos nódulos. (a) Imagem de mamografia utilizada. (b) Imagem pré-processada. (c) Saída do *k-means*. (d) Imagem dos 3 descritores somados. (e) Imagem binarizada. (f) pós processamento sobre a imagem binarizada. (g) imagem final



Fonte: Elaborado pelo autor (2019).

3.3.3 Metodologia para avaliação e interpretação

Para medir a precisão dos classificadores utilizados para a segmentação dos nódulos em imagens de mamografia digital, utiliza-se três medidas comumente empregadas: acurácia, sensibilidade e especificidade (SANTOS, 2015).

Tais medidas estão relacionadas nesta pesquisa com a capacidade do classificador para diagnosticar regiões, tais como:

- Diagnosticar uma região que representa um nódulo onde realmente corresponde a uma área que possui nódulo (Verdadeiro Positivo - VP);
- Diagnosticar uma região que representa nódulo em uma área saudável (Falso Positivo - FP);

- Diagnosticar uma região que representa uma região saudável onde realmente corresponde a uma área saudável (Verdadeiro Negativo - VN); e,
- Diagnosticar uma região que representa uma região saudável em uma área que corresponde a um nódulo (Falso Negativo - FN).

Pode-se observar cada um desses parâmetros na chamada matriz de confusão, matriz esta que representa o resultado obtido no classificador.

Quadro 1 — Matriz de confusão em um teste de detecção de presença/ausência de doença

Resultado	Doença	
	Presente	Ausente
Positivo	Verdadeiro Positivo (VP)	Falso Positivo (FP)
Negativo	Falso Negativo (FN)	Verdadeiro Negativo (VN)

Fonte: Vieira (2014).

A medida de acurácia (Ac) mede a taxa de classificação correta global, ou seja, a capacidade do classificador de identificar corretamente quando possui e não possui a presença de anomalias (COSTA, 2012). Ainda de acordo com o autor, a acurácia é definida como a relação entre o número de casos corretamente classificados com o número total de sinais analisados:

$$Ac = \frac{VP+VN}{VP+VN+FP+FN} \quad (27)$$

A medida de sensibilidade (Sen) mede a capacidade do classificador de identificar corretamente a presença da anomalia quando ela de fato existe, sendo definida pela relação entre o número de casos corretamente classificados com a presença de anomalia e a quantidade total de casos com anomalias (VIEIRA, 2014):

$$Sen = \frac{VP}{VP + FN} \quad (28)$$


A medida de especificidade (Esp) mede a capacidade do classificador em identificar corretamente a ausência de anomalias quando de fato ela não existe, sendo definida pela relação entre o número de casos corretamente classificados como saudáveis e a quantidade total de casos de estado saudável (SANTOS, 2015):

$$Esp = \frac{VN}{VN + FP} \quad (29)$$

De acordo com Vieira (2014) o classificador apresenta um bom desempenho quando é capaz de obter altos valores para as medidas de acurácia, sensibilidade e especificidade. Dessa forma, a diferenciação entre as classes atinge maior precisão, tendo em vista que a representação das medidas de sensibilidade e especificidade se tornam mais claras quando se trata da diferenciação entre uma classe saudável e uma classe com anomalia (SANTOS, 2015).

Segundo Cristiano (2017), para avaliar a capacidade de um classificador em testes diagnósticos de diferenciação entre classes saudáveis e com anomalia, é comum se utilizar uma curva de Característica de Operação do Receptor (*Receiver Operating Characteristic* - ROC). O autor ainda afirma que a curva ROC permite fazer análises visuais entre a sensibilidade e a especificidade relativamente a diversos pontos de corte, a qual a curva é obtida por meio do cálculo da sensibilidade e especificidade para cada ponto de corte e representam-se graficamente os pontos de coordenadas (1 - especificidade, sensibilidade), onde 1 - especificidade é representada no eixo das abscissas e a sensibilidade é a representada no eixo das ordenadas, em que variam de 0 a 1 (0 - 100%).

Figura 17 — Exemplo de Gráfico ROC básico com 5 classificadores discretos




Fonte: Adaptado de Fawcett (2006).

Na Figura 17, pode-se observar que os pontos (0,0) e (1,1) têm por propriedade nunca apresentarem, respectivamente, classificação Positiva e Negativa, enquanto que o ponto D (0,1) representa uma classificação perfeita (GONÇALVES, 2008).

Na análise da curva ROC, um dos principais índices de diferenciação do sistema sob análise é a área sob a curva (*Area Under the ROC Curve* - AUC) (SOVIERZOSKI, 2009). A AUC é uma métrica resumo usual do desempenho de um teste, visto que ela é estimada levando

em consideração todas as Especificidades e Sensibilidades relativas a cada um dos valores para construção do gráfico, a qual pode-se utilizar essa característica na comparação dos testes de diagnósticos, em que quanto maior for a área sob a curva ROC, maior a exatidão (FREITAS, 2016). Silva (2004) afirma que o valor da área igual a 1 representa um teste perfeito, enquanto que a área igual a 0.5 representa um valor sem importância. A Figura 18 exemplifica diversas curvas ROC e o Quadro 2 associa a qualidade do diagnóstico à área da curva ROC.

Figura 18 — Curva ROC e a qualidade no diagnóstico



Fonte: Silva (2004).

Quadro 2 — Qualidade do diagnóstico em relação a área da curva ROC

Área (AUC)	Qualidade do diagnóstico
0.9 a 1.0	Excelente
0.8 a 0.9	Bom
0.7 a 0.8	Regular
0.6 a 0.7	Ruim
0.5 a 0.6	Insignificante

Fonte: Silva (2004).

4 RESULTADO E DISCUSSÕES

Nesta seção, são apresentados os resultados obtidos na pesquisa realizada de acordo com a metodologia proposta, que compreendem as etapas de análise estatística, a classificação e identificação de textura de imagens de mamografia.

4.1 Análise estatística dos descritores de Haralick como medidas para classificação de textura da mamografia

As informações obtidas a partir da análise estatística realizada pelo software IBM SPSS *Statistics* estão expostas na Tabela 1, onde são apresentados os níveis de significância (ρ), médias e desvio padrão entre os grupos 0 (sem nódulo) e 1 (com nódulo). Para tanto, foram analisados todos os descritores de textura com exceção do Coeficiente de Correlação Máximo devido ao tempo de processamento gasto na detecção dos valores próprios da tabela Q, assim como afirma Pavusa Junior (2012).

Tabela 1 — Valor da média, desvio padrão e significância de cada descritor.

Descritores	Sem nódulo		Com nódulo		ρ
	Média	Desvio Padrão	Média	Desvio Padrão	
Segundo Momento Angular	0,4212	0,2838	0,248834	0,1709	0,010
Contraste	0,1902	0,1631	0,397135	0,4189	0,013
Correlação	0,7830	0,1829	0,835067	0,1013	0,254
Variância	1,4174	2,9554	2,089080	2,3702	0,006
Homogeneidade	0,9104	0,0718	0,834245	0,1272	0,011
Soma das Médias	142,0550	12,5922	70,641060	21,8552	0,000
Soma da Variância	19820,8048	3612,4939	5106,494377	4015,6481	0,000
Entropia da Soma	1,8157	1,1367	2,516189	0,9174	0,090
Entropia	1,9984	1,2720	2,841275	1,1245	0,007
Variância da Diferença	0,1367	0,0916	0,204795	0,1281	0,020
Entropia da Diferença	0,5956	0,2990	0,818847	0,3194	0,015
Informações de Medidas de Correlação 1	0,7296	0,2769	0,881423	0,1044	0,017
Informações de Medidas de Correlação 2	0,7296	0,2769	0,881423	0,1044	0,017

Fonte: Elaborado pelo autor (2019).

Observa-se a partir dos resultados dos testes estatísticos, tendo em vista os níveis de significância, que os descritores Segundo Momento Angular, Variância, Soma das Médias Soma da Variância e Entropia, utilizados individualmente conseguem separar as áreas de

textura saudáveis das com anomalias, possuindo diferenças estatisticamente significativas entre os dois grupos analisados.


Por meio do gráfico *boxplots* é exposto o comportamento dos descritores de textura de Haralick utilizados nos testes. Os *boxplots* são gráficos estatísticos nos quais os valores obtidos dos descritores são ordenados de forma decrescente, podendo resumir em cinco (WICKHAM; STRYJEWSKI, 2011):

- Valor mínimo: Conhecido também como limite inferior, é o menor valor obtido do conjunto de dados analisado;
- Valor máximo: Comumente chamado de limite superior, é o maior valor obtido do conjunto de dados analisado;
- Primeiro quartil: Conhecido também como quartil inferior ou 25º percentil, é onde se localiza $\frac{1}{4}$ ou 25% dos menores valores, representada pela linha inferior da caixa.
- Segundo quartil: Chamado também de mediana ou 50º percentil, onde fica localizado no meio da caixa, representada pela linha dentro da caixa, entre a metade superior e a metade inferior da amostra.
- Terceiro quartil: Comumente conhecido como quartil superior ou 75º percentil, é onde se localiza $\frac{3}{4}$ ou 75% dos valores maiores, representada pela linha superior da caixa.

De acordo com Vieira (2012) cada parte é separada por um intervalo de 25% dos valores ordenados e os valores considerados fora da distribuição são representados por pontos acima do limite superior ou abaixo do limite inferior.


Desse modo, os gráficos *boxplots* dos descritores de Haralick, dispostos a seguir, representam a distribuição das medidas de quantificação de recorrência, onde os valores máximo e mínimos estão representados por uma pequena linha horizontal, que representa os respectivos limites; os intervalos entre o primeiro quartil e o terceiro quartil (50% centrais da distribuição) estão representados por um caixa com contorno de cor azul-turquesa, enquanto que o segundo quartil é representado por uma linha horizontal vermelha dentro da caixa com contorno de cor azul-turquesa (VIEIRA, 2012).

Gráfico 1 — Segundo Momento Angular




Fonte: Elaborado pelo autor (2019).

Gráfico 2 — Contraste




Fonte: Elaborado pelo autor (2019).

Gráfico 3 — Correlação




Fonte: Elaborado pelo autor (2019).

Gráfico 4 — Variância




Fonte: Elaborado pelo autor (2019).

Gráfico 5 — Homogeneidade




Fonte: Elaborado pelo autor (2019).

Gráfico 6 — Soma das Médias




Fonte: Elaborado pelo autor (2019).

Gráfico 7 — Soma da Variância




Fonte: Elaborado pelo autor (2019).

Gráfico 8 — Entropia da Soma




Fonte: Elaborado pelo autor (2019).

Gráfico 9 — Entropia




Fonte: Elaborado pelo autor (2019).

Gráfico 10 — Variância da Diferença




Fonte: Elaborado pelo autor (2019).

Gráfico 11 — Entropia da Diferença




Fonte: Elaborado pelo autor (2019).

Gráfico 12 — Informações de Med. Corr. 1



Fonte: Elaborado pelo autor (2019).


Gráfico 13 — Informações de Med. Corr. 2

Fonte: Elaborado pelo autor (2019).

4.2 Análise da classificação e identificação


Para os testes de classificação utilizou-se a soma dos três descritores com maior potencial discriminatório, analisados estatisticamente. Apesar do descritor Soma das Médias possuir um valor de significância menor que o definido, ao ser processada pelo classificador, o descritor não consegue distinguir um tecido doente de um saudável, não sendo assim, utilizado no teste. Desse modo, os descritores Soma da Variância, Variância e Entropia foram os que obtiveram melhores resultados mostrados na seção 4.1. A análise do método proposto é realizada a partir da comparação entre a imagem identificada com o padrão ouro. Na Figura 19 e Figura 20 é apresentado o padrão ouro das imagens com nódulo, e o padrão ouro das imagens saudáveis, respectivamente.

Figura 19 — Padrão ouro das imagens com nódulos



Fonte: Elaborado pelo autor (2019).

Figura 20 — Padrão ouro das imagens saudáveis



Fonte: Elaborado pelo autor (2019).

Avaliando os dados da Tabela 2 disposta abaixo, percebe-se que, das imagens que possuíam nódulos (primeiras quinze imagens da lista) todas apresentaram Verdadeiro Positivo (VP). As imagens constatadas pelo diagnóstico como saudáveis (últimas quinze imagens da lista), em nenhum caso apresentou-se Falso Positivo (FP) e/ou Falso Negativo (FN).

Em relação a Sensibilidade (medida do grau de acertos dos verdadeiros positivos), das quinze imagens que continham nódulos, apenas duas imagens classificadas pelo sistema ficaram abaixo de 60% de acerto, enquanto que a maioria das imagens classificadas obtiveram sensibilidade maior que 80%.

No que se refere a Especificidade (medida do grau de acertos dos verdadeiros negativos) todas as imagens cujo diagnóstico possuía nódulo, obtiveram uma taxa de acerto acima de 99% com exceção da imagem mdb184 que obteve uma taxa de 98%. Nas imagens saudáveis, a especificidade alcançou média de 100% de acerto, ou seja, em todos os casos de imagens cujo diagnóstico era saudável, o método classificou como saudáveis.

Em termos de Acurácia (medida do grau de acertos global), os resultados obtidos são relevantes, visto que das imagens que continham nódulos apenas duas imagens obtiveram taxa de 98% (mdb150 e mdb184), enquanto que todas as outras obtiveram uma taxa acima de 99%. Das imagens diagnosticada como saudáveis, todas as imagens alcançaram uma taxa de 100% de acerto.

Tabela 2 — Resultados obtidos para cada imagem a partir do método utilizado
(Continua)

Imagens	VP	FP	VN	FN	Sensibilidade	Especificidade	Acurácia
mdb010	1380	260	435166	260	0.861423	0.999403	0.998897
mdb021	2727	2487	498426	2340	0.538188	0.995035	0.99046
mdb023	1768	374	531639	158	0.917965	0.999297	0.999004
mdb025	8275	460	661085	740	0.917915	0.999305	0.99821
mdb028	6040	1929	515155	1	0.999834	0.996269	0.996311
mdb083	2296	2598	487140	73	0.969185	0.994695	0.994572
mdb117	3243	1816	427149	1292	0.715105	0.995767	0.99283
mdb132	1772	242	626044	774	0.695994	0.999614	0.998384
mdb134	4996	948	908354	134	0.973879	0.998957	0.998817
mdb150	14548	5953	652955	4844	0.750206	0.990965	0.984082
mdb155	1692	1297	630164	25	0.98544	0.997946	0.997912
mdb184	16756	9180	567657	0	1	0.984086	0.984535


Tabela 2 — Resultados obtidos para cada imagem a partir do método utilizado

							(Conclusão)
Imagens	VP	FP	VN	FN	Sensibilidade	Especificidade	Acurácia
mdb202	2022	631	1045763	160	0.926673	0.999397	0.999246
mdb264	1100	1262	507061	1553	0.414625	0.997517	0.994491
mdb271	5365	33	614289	1569	0.773724	0.999946	0.997421
mdb006	0	0	573440	0	0	1	1
mdb060	0	0	359424	0	0	1	1
mdb077	0	0	537747	0	0	1	1
mdb131	0	0	582736	0	0	1	1
mdb133	0	0	858162	0	0	1	1
mdb140	0	0	705425	0	0	1	1
mdb232	0	0	530880	0	0	1	1
mdb272	0	0	592524	0	0	1	1
mdb298	0	0	528384	0	0	1	1
mdb299	0	0	573440	0	0	1	1
mdb301	0	0	452505	0	0	1	1
mdb302	0	0	397332	0	0	1	1
mdb304	0	0	388068	0	0	1	1
mdb306	0	0	469216	0	0	1	1
mdb310	0	0	572260	0	0	1	1

Fonte: Elaborado pelo autor (2019).


Desse modo, a Figura 21 e a Figura 22 apresentam as demarcações realizadas pelo método proposto das imagens com nódulos e imagens saudáveis, respectivamente. Percebe-se que nas imagens mdb021 (Figura 21(a)), mdb177 (Figura 21(g)) e mdb150 (Figura 21(j)) apresentaram falsos positivos, enquanto que na imagem mdb132 (Figura 21(h)) apresentou falso negativo. A Figura 22 onde se apresentam as imagens saudáveis, não houve nenhuma demarcação, entendendo-se que o método acertou em todos os casos de diagnóstico saudável.

Figura 21 — Resultados obtidos com as imagens diagnosticadas com nódulos



Fonte: Elaborado pelo autor (2019).

Figura 22 — Resultados obtidos com as imagens diagnosticadas sem nódulo




Fonte: Elaborado pelo autor (2019).

Assim, em termos gerais, o método proposto alcançou um percentual de acerto de 84,19% de sensibilidade, 99,82% de especificidade e 99,75% de acurácia, resultados significativamente relevantes.

Desse modo, como forma de mensurar a qualidade do diagnóstico realizado pelo classificador, calculou-se a área sob a curva ROC, utilizando um intervalo de confiança de 99%. Para isto, a curva foi construída a partir de 300 amostras obtidas de 15 imagens de mamografia digital com nódulo após serem processadas pelo classificador. Para cada imagem foram extraídos 10 valores de *pixels* localizados em regiões de nódulos e 10 *pixels* de regiões saudáveis. Os dados foram analisados pelo software SPSS *Statistics* adotando um nível de significância de 1%. A curva ROC é apresentada no Gráfico 14.

Gráfico 14 - Curva ROC para o classificador utilizado



Fonte: Elaborado pelo autor (2019).

Com isso a área de 0,925 obtida sob a curva, indica um valor que de acordo com Silva (2004), mostra que o classificador possui uma excelente qualidade de diagnóstico, certificando então o desempenho do sistema aqui proposto.

5 CONCLUSÃO

Nesta seção, serão apresentadas as considerações acerca da pesquisa realizada, bem como as sugestões para trabalhos futuros.

5.1 Considerações Finais

A análise de textura em imagens digitais quando utilizadas em sistemas de auxílio ao diagnóstico médico podem apresentar bons resultados. Pesquisas mostram que a análise de textura possui um papel fundamental em imagens médicas, visto que, em imagens de mamografia digital as regiões com nódulos e regiões saudáveis podem apresentar características de textura capazes de diferenciar uma região de outra.

Este trabalho teve como objetivo desenvolver um método de visão computacional para identificação de nódulos em mamografias digitais por meio de análise de textura. Para tanto, realizou-se uma análise estatística com testes de hipóteses, com o intuito de avaliar o potencial discriminatório dos descritores de Haralick, constatando que tais descritores possuem para a aplicação que se propõe nesta pesquisa, diferenças significativas entre os grupos de textura com nódulos e textura saudáveis.

A partir disso, com o intuito de atingir o objetivo, surgiu o interesse de aplicar técnicas de visão computacional e processamento digital de imagens, bem como classificação de padrões, para desenvolver um método computacional capaz de realizar a identificação de nódulos em imagens de mamografia digital.

Por meio dos testes realizados com o classificador, os resultados obtidos para as medidas de sensibilidade (84,19%), especificidade (99,82%) e acurácia (99,75%) foram significativos. A área sob a curva obtida para o classificador utilizado foi de 0,925, mostrando que o método proposto possui um bom desempenho e uma excelente qualidade de classificação.

Assim, percebe-se que o objetivo geral foi atingido, visto que os resultados obtidos quando comparados com outros trabalhos da literatura, apresentam números de desempenho muito significativos, alcançando um percentual de classificação relevante, que revelam uma boa performance na identificação de nódulos mamários. Cabe ressaltar que o método proposto desenvolve a identificação sem nenhuma intervenção humana.

Portanto, a partir das análises realizadas nesta pesquisa, pode-se constatar que os descritores de Haralick quando utilizados em imagens de mamografia digital para identificação de nódulos, apresentam-se como uma técnica relevante e promissora.

5.2 Trabalhos Futuros

Sugere-se como pesquisas em trabalhos futuros, proposta que busquem:

- Aplicar o método proposto em diferentes patologias da mama;
- Analisar resultados obtidos por outros classificadores, tais como redes neurais artificiais Perceptron de Múltiplas Camadas (*Multilayer Perceptron* - MLP) e Máquinas Vetores de Suporte (*Support Vector Machines* - SVM);
- Melhorar o algoritmo para combinação dos descritores de haralick e analisar quais os melhores grupos;
- Melhorar o algoritmo para definir a quantidade de clusters automaticamente por meio do método de *Elbow*.
- Investigar a utilização de outros algoritmos para análise de texturas, como o *Local Binary Pattern* (LBP);
- Estudar a combinação entre diferentes métodos de mensuração de textura.

REFERÊNCIAS

ABDUL-NASIR, Aimi Salihah; MASHOR, Mohd Yusoff; MOHAMED, Zeehaida. Colour image segmentation approach for detection of malaria parasites using various colour models and k-means clustering. **WSEAS transactions on biology and biomedicine**, v. 10, n. 1, p. 41-55, 2013.

AGUIAR, Cecília Burle de. **Avaliação de Acidente Vascular Cerebral em Tomografia Computadorizada Utilizando Algoritmo de Otimização de Formigas**. 2017. 123 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Instituto Federal de Educação, Ciência e Tecnologia da Paraíba, João Pessoa, 2017.

ALAM, Janee; ALAM, Sabrina; HOSSAN, Alamgir. Multi-Stage Lung Cancer Detection and Prediction Using Multi-class SVM Classifier. In: **2018 International Conference on Computer, Communication, Chemical, Material and Electronic Engineering (IC4ME2)**. IEEE, 2018. p. 1-4.

BARRA, Daniela Couto Carvalho et al. Evolução histórica e impacto da tecnologia na área da saúde e da enfermagem. **Revista Eletrônica de Enfermagem**, [s.l.], v. 08, n. 03, p.422-430, dez. 2006. Disponível em: <http://www.fen.ufg.br/revista/revista8_3/v8n3a13.htm>. Acesso em: 09 mar. 2018.

BONTRAGER, Kenneth L.. **Tratado de Técnica Radiológica e Base Anatômica**. 5. ed. Rio de Janeiro: Guanabara Koogan, 2003.

BUENO, Josiane M.. **Suporte à Recuperação de Imagens Médicas Baseada em Conteúdo através de Histogramas Métricos**. 2001. 162 f. Tese (Doutorado) - Curso de Ciências, Departamento de Ciências de Computação e Estatística, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2001.

COSTA, Ronaldo Martins da. **Uma nova abordagem para reconhecimento biométrico baseado em características dinâmicas da íris humana**. 2009. 119 f. Tese (Doutorado) - Curso de Engenharia de Eletricidade, Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2009.

COSTA, Washington César de Almeida. **Análise Dinâmica Não Linear de Sinais de Voz para Detecção de Patologias Laríngeas**. 2012. 178 f. Tese (Doutorado) - Curso de Engenharia Elétrica, Departamento de Engenharia Elétrica, Universidade Federal de Campina Grande, Campina Grande, 2012.

CRISTIANO, Mariana Vitória de Menezes Bordalo. **Sensibilidade e Especificidade na Curva ROC Um Caso de Estudo**. 2017. 126 f. Dissertação (Mestrado) - Curso de Gestão de Sistemas de Informação Médica, Escola Superior de Tecnologia e Gestão do Instituto Politécnico de Leiria, Leiria, 2017.

DHANACHANDRA, Nameirakpam; MANGLEM, Khumanthem; CHANU, Yambem Jina. Image segmentation using K-means clustering algorithm and subtractive clustering algorithm. **Procedia Computer Science**, v. 54, p. 764-771, 2015.

DINIZ, João Otávio Bandeira. **Detecção de regiões de massa por análise bilateral adaptada à densidade da mama utilizando índices de similaridade e redes neurais convolucionais**. 2017. 78 f. Dissertação (Mestrado) - Curso de Ciência da Computação, Departamento de Informática/ccet, Universidade Federal do Maranhão, São Luís, 2017.

ESPADARO, Jéssica Ferreira et al. Mamografia: Histórico da Mamografia e Suas Aplicações. **Revista Conexão Eletrônica**, Três Lagoas, v. 15, n. 1, p.2167-2179, 2018.

FAWCETT, Tom. An introduction to ROC analysis. **Pattern recognition letters**, v. 27, n. 8, p. 861-874, 2006.

FERLAY, Jacques et al. Cancer incidence and mortality worldwide: Sources, methods and major patterns in GLOBOCAN 2012. **International Journal Of Cancer**, [s.l.], v. 136, n. 5, p.359-386, 9 out. 2014. Wiley. <http://dx.doi.org/10.1002/ijc.29210>. Disponível em: <<https://onlinelibrary.wiley.com/doi/epdf/10.1002/ijc.29210>>. Acesso em: 24 fev. 2018.

FERNANDES, Flávia Gonçalves; BARBOSA, João Ludovico Maximiano; PATROCÍNIO, Ana Cláudia. Sistema de extração e seleção de atributos em imagens. In: **Conferência de Estudos em Engenharia Elétrica (CEEL)**, 14, 2016, Uberlândia. Uberlândia: Universidade Federal de Uberlândia - Ufu, 2016.

FERNANDES, Sandro R.; ASSIS, Joaquim T. de; LIMA, Inaya Correa Barbosa. DESENVOLVIMENTO DE UMA METODOLOGIA PARA ANÁLISE DE IMAGENS DE MICROTOMOGRÁFIA DE RAIOS X BASEADA EM ABORDAGENS ESTATÍSTICAS. In: **MECÂNICA COMPUTACIONAL - MECOM**, Buenos Aires. v. 29, p. 6257 - 6266, 2010.

FREITAS, Emannuel Diego Gonçalves de. **Segmentação de Regiões de AVC Isquêmicos em Imagens de TC por meio da Classificação de Textura**. 2016. 163 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Instituto Federal de Educação, Ciência e Tecnologia da Paraíba - Campus João Pessoa, João Pessoa, 2016.

GAIKE, Vrushali et al. Clustering of breast cancer tumor using third order GLCM feature. In: **2015 International Conference on Green Computing and Internet of Things (ICGCIoT)**. IEEE, 2015. p. 318-322.

GHONGADE, R. D.; WAKDE, D. G. Computer-aided diagnosis system for breast cancer using RF classifier. In: **2017 International Conference on Wireless Communications, Signal Processing and Networking (WiSPNET)**. IEEE, 2017. p. 1068-1072.

GIL, Antonio Carlos. **Como elaborar projetos de pesquisa**. 4. ed. São Paulo: Editora Atlas S.A., 2002.

GIL, Antonio Carlos. **Métodos e técnicas de pesquisa social**. 6. ed. São Paulo: Editora Atlas S.A., 2008.

GÓIS, Renata de Freitas. **Investigação do uso de imagens mamográficas adquiridas em diferentes digitalizadores no desempenho do processamento de imagens para detecção de microcalcificações**. 2006. 118 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Departamento de Engenharia Elétrica, Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2006.

GONÇALVES, Diego Bertolini. **Agrupamento de classificadores na verificação de assinaturas off-line**. 2008. 86 f. Dissertação (Mestrado) - Curso de Informática, Pontifícia Universidade Católica do Paraná, Curitiba, 2008.

GONZALEZ, Rafael C.; WOODS, Richard C.. **Processamento digital de imagens**. 3. ed. São Paulo: Pearson Prentice Hall, 2010. 644 p. Tradução de: Cristina Yamagami e Leonardo Piamonte.

HALL-BEYER, Mryka. **GLCM TEXTURE: A TUTORIAL**. Calgary: Universidade de Calgary, 2017. 75 p.

HARALICK, Robert M. SHANMUGAM, K.; DINSTEN, I.. Textural features for image classification. **IEEE Transactions on systems, man, and cybernetics**, n. 6, p. 610-621, 1973.

HAUS, Arthur G. Technological improvements in mammography over the past 20 years. **Medical progress through technology**, v. 19, n. 1, p. 31-42, 1993.

HEMMINGER, Bradley M. et al. Evaluation of digital processing methods for the display of digital mammography. In: **Medical Imaging 1999: Image Display**. International Society for Optics and Photonics, 1999. p. 382-394.

HU, Ming-Kuei. Visual pattern recognition by moment invariants. **IRE transactions on information theory**, v. 8, n. 2, p. 179-187, 1962.

IBM. **SPSS Statistics**. 2019. Disponível em: <<https://www.ibm.com/br-pt/products/spss-statistics/details>>. Acesso em: 20 abr. 2019.

INCA, Instituto Nacional de Câncer José Alencar Gomes da Silva. **Atualização em mamografia para técnicos em radiologia**. Rio de Janeiro: INCA, 2019.

INCA, Instituto Nacional de Câncer José Alencar Gomes da Silva. **Estimativa 2018: incidência de câncer no Brasil**. Rio de Janeiro: INCA, 2017.

INCA, Instituto Nacional de Câncer José Alencar Gomes da Silva. **Falando sobre o câncer de mama**. Rio de Janeiro: INCA, 2002.

JAMSA, Kris; KLANDER, Lars. **Programando em C/C++: a Bíblia**. São Paulo: Makron Books, 1999.

JIAN, Muwei; LIU, Lei; GUO, Feng. Texture image classification using perceptual texture features and Gabor wavelet features. In: **2009 Asia-Pacific Conference on Information Processing**. IEEE, 2009. p. 55-58.

KALAF, José Michel. Mamografia: uma história de sucesso e de entusiasmo científico. **Radiol. bras**, v. 47, n. 4, p. VII-VIII, 2014.

KASHYAP, Rangasami L.; EOM, K.-B. Texture boundary detection based on the long correlation model. **IEEE transactions on pattern analysis and machine intelligence**, v. 11, n. 1, p. 58-67, 1989.

KAUARK, Fabiana da Silva; MANHÃES, Fernanda Castro; MEDEIROS, Carlos Henrique. **Metodologia da Pesquisa: Um guia prático**. Itabuna: Via Litterarum, 2010.

LEBORGNE, Raul. Diagnosis of tumors of the breast by simple roentgenography; calcifications in carcinomas. **The American journal of roentgenology and radium therapy**, v. 65, n. 1, p. 1-11, 1951.

LI, X. et al. Classification of adrenal lesions through spatial Bayesian modeling of GLCM. In: **2017 IEEE 14th International Symposium on Biomedical Imaging (ISBI 2017)**. IEEE, 2017. p. 147-151.

MAHESH, Mahadevappa. AAPM/RSNA physics tutorial for residents: digital mammography: an overview. **Radiographics**, v. 24, n. 6, p. 1747-1760, 2004.

MARQUES, Fátima de Lourdes dos Santos Nunes. **Investigações em processamento de imagens mamográficas para auxílio ao diagnóstico de mamas densas**. 2001. 230 f. Tese (Doutorado) - Curso de Ciências, Instituto de Física de São Carlos, Universidade de São Paulo, São Carlos, 2001.

MARQUES FILHO, Ogê; VIEIRA NETO, Hugo. **Processamento Digital de Imagens**. Rio de Janeiro: Brasport, 1999.

MARTINS, Wilson Denis. Wilhelm Conrad Roentgen e a Descoberta dos Raios-X. **Archives of Oral Research**, v. 1, n. 3, 2005.

MENKE, Carlos H. *et al.* **Rotinas em mastologia**. 2. ed. Porto Alegre: Artmed, 2007.

MOORE, Keith L.; DALLEY, Arthur F.; AGUR, Anne M. R.. **Moore Anatomia Orientada para a Clínica**. 7. ed. Rio de Janeiro: Koogan, 2014. Tradução de: Claudia Lucia Caetano de Araujo.

OLIVEIRA, Márcia Silva de. **Análise de Textura em Imagens Cerebrais: aplicações em Acidente Vascular Cerebral Isquêmico, Epilepsia Mioclônica Juvenil, Doença de Machado-Joseph, Déficit Cognitivo Leve e Doença de Alzheimer**. 2010. 145 f. Tese (Doutorado) - Universidade Estadual de Campinas, Instituto de Física "Gleb Wataghin", Campinas, 2010.

OTSU, Nobuyuki. A threshold selection method from gray-level histograms. **IEEE transactions on systems, man, and cybernetics**, v. 9, n. 1, p. 62-66, 1979.

PARKER, Jim R. **Algorithms for image processing and computer vision**. John Wiley & Sons, 2010.

PASSOS, Eduardo Pandolfi et al. **Rotinas em ginecologia**. Artmed Editora, 2017.

PAVUSA JUNIOR, Roberto. **Metodologia automatizada para a segmentação e classificação da densidade mamográfica utilizando descritores de coocorrência, estatísticos e surf**. 2012. 125 f. Dissertação (Mestrado) - Curso de Engenharia Biomédica, Universidade de Mogi das Cruzes, Mogi das Cruzes, 2012.

PEDRINI, Hélio; SCHWARTZ, William Robson. **Análise de imagens digitais: princípios, algoritmos e aplicações**. Thomson Learning, 2008.

PEREIRA, Miguel Basto et al. Grupo etário e periodicidade recomendados para a mamografia de rastreio: uma revisão sistemática. **Ciência & Saúde Coletiva**, [s.l.], v. 19, n. 4, p.1135-1140, abr. 2014. FapUNIFESP (SciELO). <http://dx.doi.org/10.1590/1413-81232014194.22112012>. Disponível em: <<http://www.scielo.br/pdf/csc/v19n4/1413-8123-csc-19-04-01135.pdf>>. Acesso em: 10 jun. 2018.

PÉREZ, María et al. Mammogram classification using back-propagation neural networks and texture feature descriptors. In: **2017 IEEE Second Ecuador Technical Chapters Meeting (ETCM)**. IEEE, 2017. p. 1-6.

PIRNOG, Ionut et al. Automatic lesion segmentation for melanoma diagnostics in macroscopic images. In: **2015 23rd European Signal Processing Conference (EUSIPCO)**. IEEE, 2015. p. 659-663.

PORTO, Fuad Nacif. **Análise de sensibilidade de um sistema CAD para mamografia digital**. 2010. 69 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Universidade Federal de Minas Gerais, Belo Horizonte, 2010.

PRODANOV, Cleber Cristiano; FREITAS, Ernani Cesar. **METODOLOGIA DO TRABALHO CIENTÍFICO: Métodos e Técnicas da Pesquisa e do Trabalho Acadêmico**. 2. ed. Novo Hamburgo: Universidade Feevale, 2013.

Qt. **Qtcreator**. 2019. Disponível em: < <https://www.qt.io/what-is-qt/>>. Acesso em: 20 abr. 2019.

RADOVIC, Milos et al. Application of data mining algorithms for mammogram classification. In: **13th IEEE International Conference on BioInformatics and BioEngineering**. IEEE, 2013. p. 1-4.

RAGHAVENDRA, U. et al. Application of Gabor wavelet and Locality Sensitive Discriminant Analysis for automated identification of breast cancer using digitized mammogram images. **Applied Soft Computing**, v. 46, p. 151-161, 2016.

RENNÓ, Camilo Daleles. **Avaliação de medidas texturais na discriminação de classes de uso utilizando imagens sir-c/x-sar do perímetro irrigado de bebedouro, Petrolina, PE**. 2004. 109 v. Tese (Doutorado) - Curso de Sensoriamento Remoto, Instituto Nacional de Pesquisas Espaciais, São José dos Campos, 2004.

RIBEIRO, Patricia Bellin. **Classificação por análise de contornos de nódulos mamários utilizando redes neurais artificiais**. 2006. 152 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Departamento de Engenharia Elétrica, Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2006.

RIBEIRO, Patricia Bellin. **Esquema CADx para classificação de nódulos em imagens mamográficas digitais baseado na segmentação pelo modelo EICAMM**. 2013. 242 f. Tese (Doutorado) - Curso de Engenharia Elétrica, Departamento de Engenharia Elétrica, Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2013.

ROCHA, Simara Vieira da. **Diferenciação do Padrão de Malignidade e Benignidade de Massas em Imagens de Mamografias Usando Padrões Locais Binários, Geoestatística e Índice de Diversidade**. 2014. 107 f. Dissertação (Mestrado) - Curso de Engenharia de Eletricidade, Centro de Ciências Exatas e Tecnologia, Universidade Federal do Maranhão, São Luís, 2014.

SANTOS, Mikaelle Oliveira. **Análise Acústica de Desvios Vocais Infantis utilizando a Transformada Wavelet**. 2015. 80 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Instituto Federal de Educação, Ciência e Tecnologia da Paraíba, João Pessoa, 2015.

SANTOS, Vivian Toledo. **Segmentação de imagens mamográficas para detecção de nódulos em mamas densas**. 2002. 121 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2002.

SCHILDT, Herbert. **C Completo e Total**. 3. ed. São Paulo: Makron Books, 1996. 816 p.

SCHLEIP, Robert; JÄGER, Heike; KLINGLER, Werner. What is 'fascia'? A review of different nomenclatures. **Journal of bodywork and movement therapies**, v. 16, n. 4, p. 496-502, 2012.

SCHWARTZ, William Robson; PEDRINI, Hélio. Segmentação de imagens de terrenos baseada na associação de características de texturas com dependência espacial modelada por campo aleatório de Markov. In: **XII Simpósio Brasileiro de Sensoriamento Remoto**. 2005. p. 4311-4318.

SCHWARTZ, William Robson. **Segmentação de imagens baseada em dependência espacial utilizando campo aleatório de Markov associado com características de texturas**. 2005. 120 f. Dissertação (Mestrado) - Curso de Informática, Universidade Federal do Paraná, Curitiba, 2005.

SHARMA, Mona. **Performance Evaluation of Image Segmentation and Texture Extraction Methods in Scene Analysis**. 2001. 227 f. Dissertação (Mestrado) - Curso de Filosofia em Ciência da Computação, University Of Exeter, Exeter, 2001.

SILVA, Aristófares Corrêa. **Algoritmos para Diagnóstico Assistido de Nódulos Pulmonares Solitários em Imagens de Tomografia Computadorizada**. 2004. 141 f. Tese (Doutorado) - Curso de Informática, Departamento de Informática, Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, 2004.

SILVA, Leandro Augusto da. **Classificação de Nódulos Mamográficos Utilizando um Comitê de Redes Neurais Artificiais**. 2005. 111 f. Dissertação (Mestrado) - Curso de Engenharia, Escola Politécnica, Universidade de São Paulo, São Paulo, 2005.

SOUTO JUNIOR, Carlos Alberto. **Avaliação de Descritores de Textura para Segmentação Não-Supervisionada de Imagens**. 2010. 138 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Faculdade de Engenharia Elétrica e de Computação, Campinas, 2010.

SOVIERZOSKI, Miguel Antonio. **Avaliação de descritores morfológicos na identificação de eventos epileptiformes**. 2009. 203 f. Tese (Doutorado) - Curso de Engenharia Elétrica, Universidade Federal de Santa Catarina, Florianópolis, 2009.

SUCKLING J, P. The mammographic image analysis society digital mammogram database. **Digital Mammo**, p. 375-386, 1994.

TAKAHASHI, Adriana; BEDREGAL, Benjamin René Callejas; LYRA, Aarão. Uma versão intervalar do método de segmentação de imagens utilizando o k-means. **Trends in Applied and Computational Mathematics**, v. 6, n. 2, p. 315-324, 2005.

VENTURA, Viviane de Almeida. **Representação de Imagens Através de Grafos Utilizando o Algoritmo Split-And-Merge Combinado com Descritores de Cor e Textura**. 2009. 123 f. Dissertação (Mestrado) - Curso de Ciência da Computação, Universidade Federal do Espírito Santo, Vitória, 2009.

VIEIRA, Vinícius Jefferson Dias. **Avaliação de Distúrbios da Voz por meio de Análise de Quantificação de Recorrência**. 2014. 218 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Instituto Federal de Educação, Ciência e Tecnologia da Paraíba, João Pessoa, 2014.

VIEIRA, Vinícius Jefferson Dias. **Caracterização de Sinais de Vozes Saudáveis e Sinais de Vozes Patológicas por meio da Análise de Quantificação de Recorrência**. 2012. 89 f. TCC (Graduação) - Curso de Tecnologia em Sistemas de Telecomunicações, Instituto Federal de Educação, Ciência e Tecnologia da Paraíba, João P, 2012.

WICKHAM, Hadley; STRYJEWSKI, Lisa. 40 years of boxplots. **Am. Statistician**, 2011.